

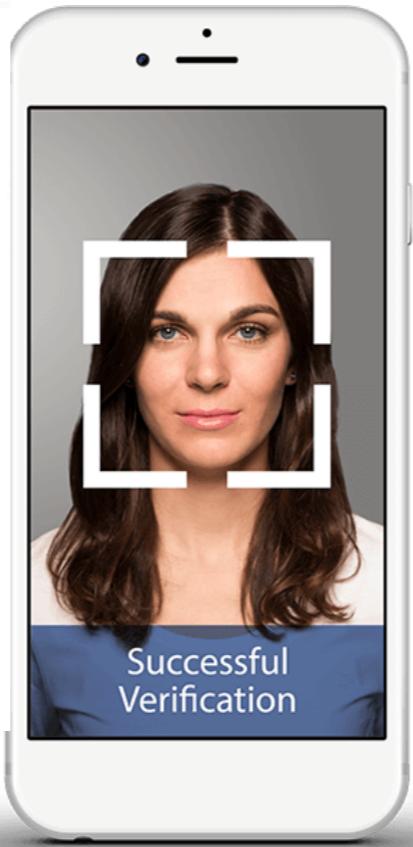
13. Redes Neuronales Convolucionales CNN



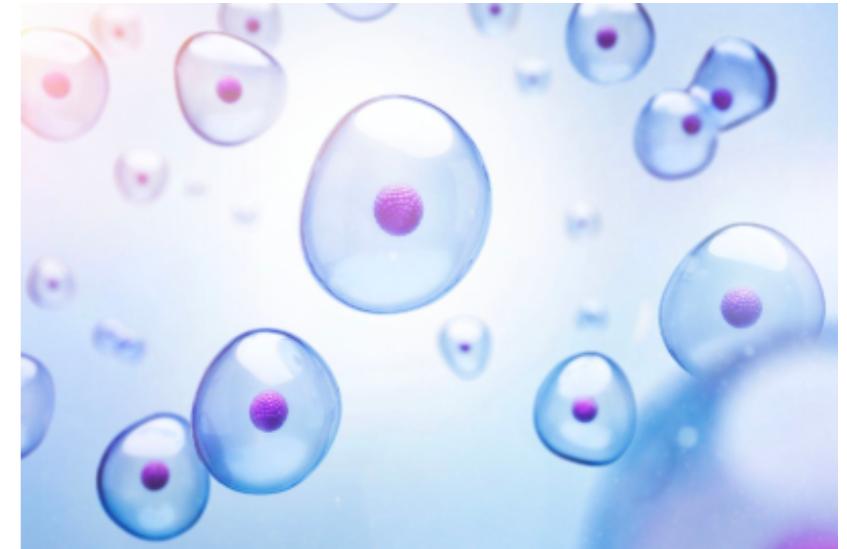
Aplicaciones



Robótica



Dispositivos móviles



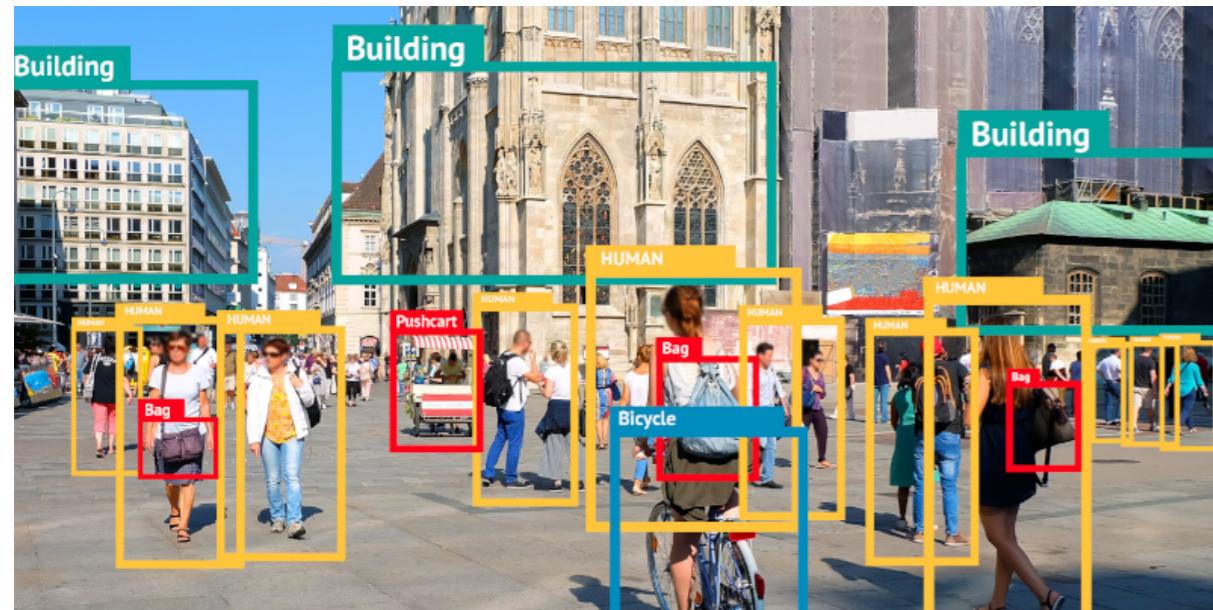
Biología



Medicina



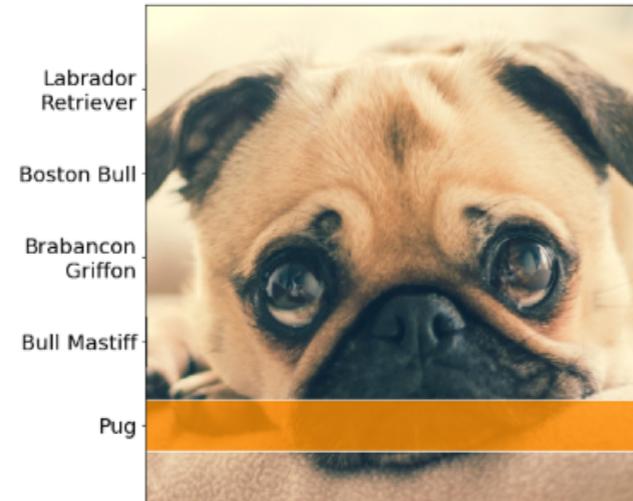
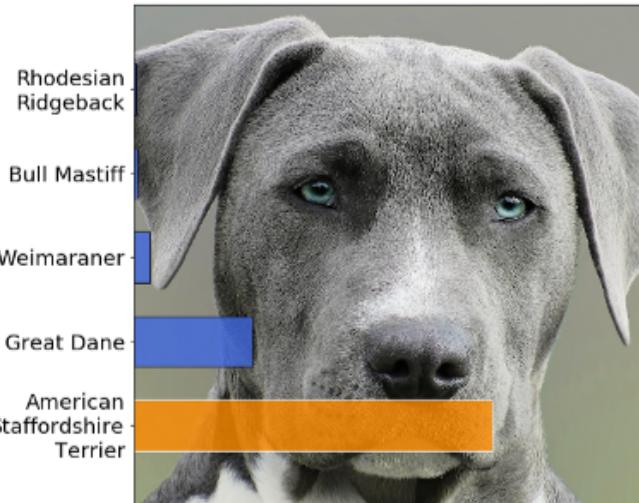
Conducción autónoma



Detección de objetos



Reconocimiento de caras

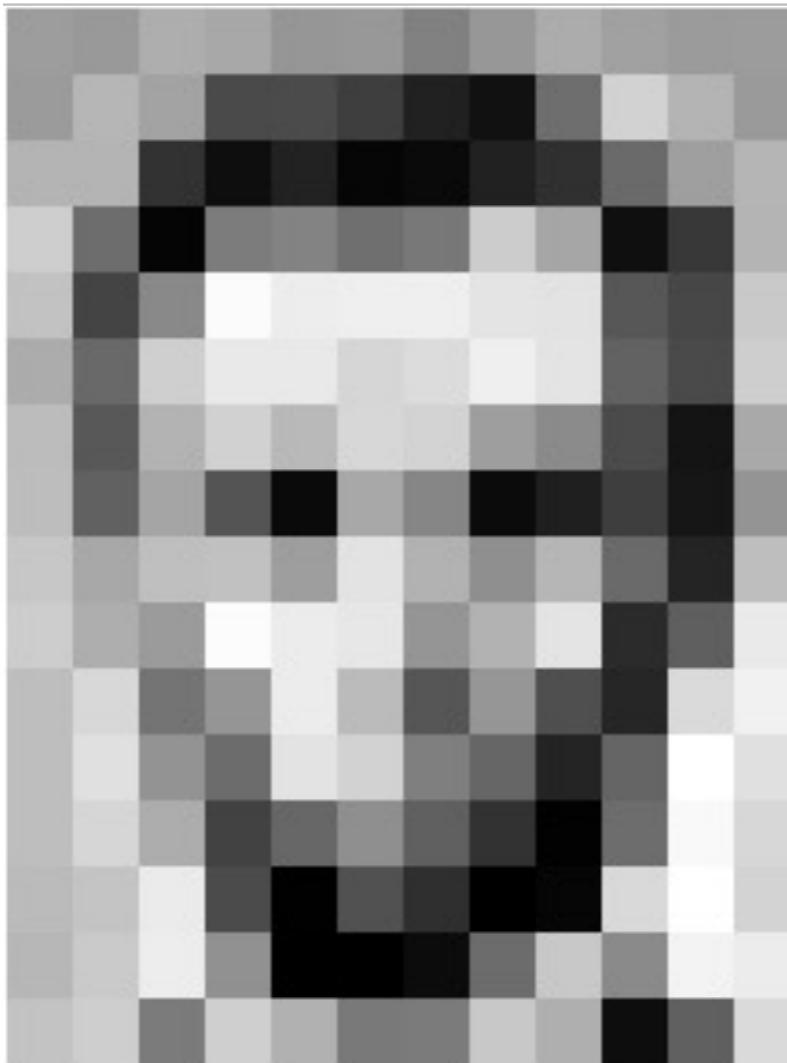


Clasificación / Regresión



Segmentación semántica

Funcionamiento de las CNN



Clasificación
→

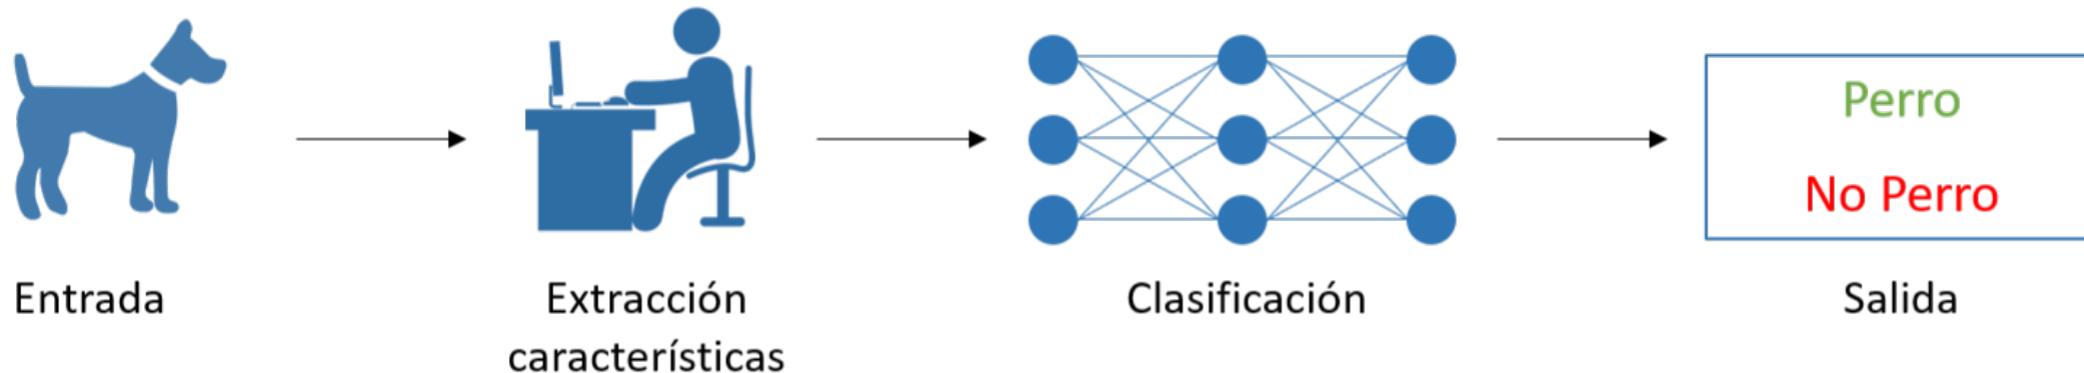
Clases	Probabilidad
Lincoln	0.8
Washington	0.1
Jefferson	0.05
Obama	0.05

Imagen de entrada

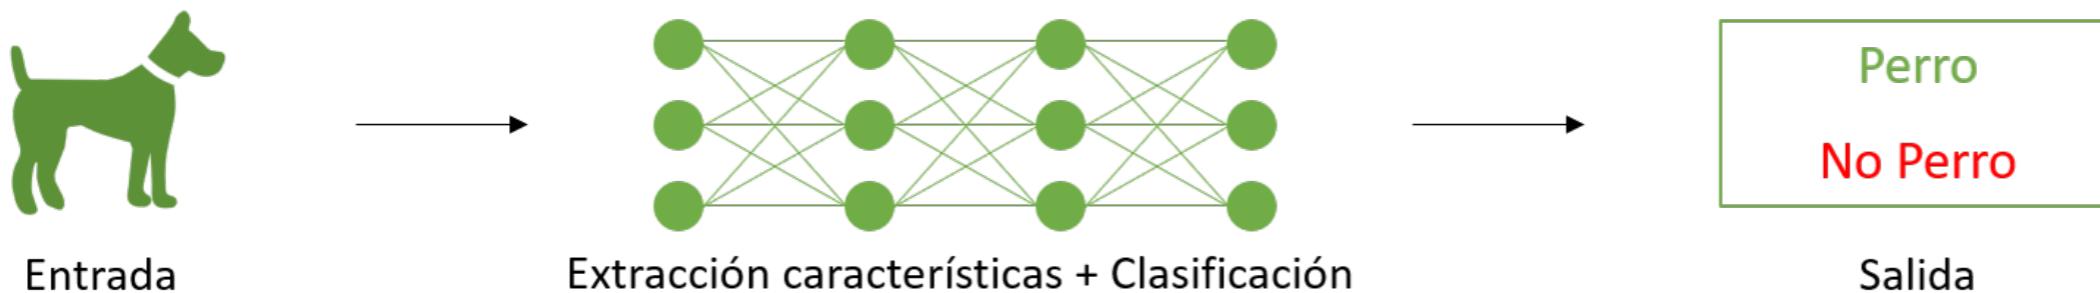
Salida

Representación de las imágenes

Machine Learning



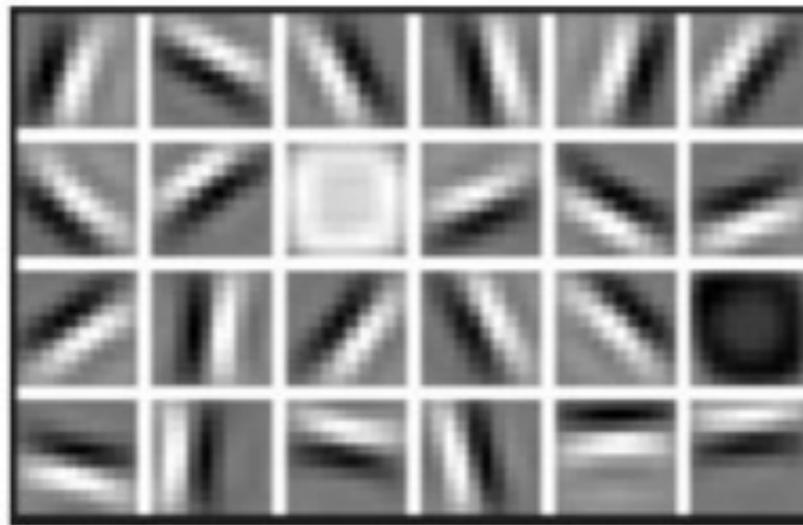
Deep Learning



Extracción de características

¿Podemos aprender **jerarquía de características** directamente de los datos en lugar de tener que extraerlas manualmente?

Las CNN extraen características a **distintos niveles** y las combinan para realizar la predicción.



Ejes, contornos



Ojos, orejas, nariz, boca



Caras

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	83	17	110	210	180	154
180	180	50	14	34	6	10	83	48	105	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	299	299	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	105	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	36	218	241
190	224	147	108	227	210	127	102	35	101	255	224
190	214	173	66	103	143	95	59	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

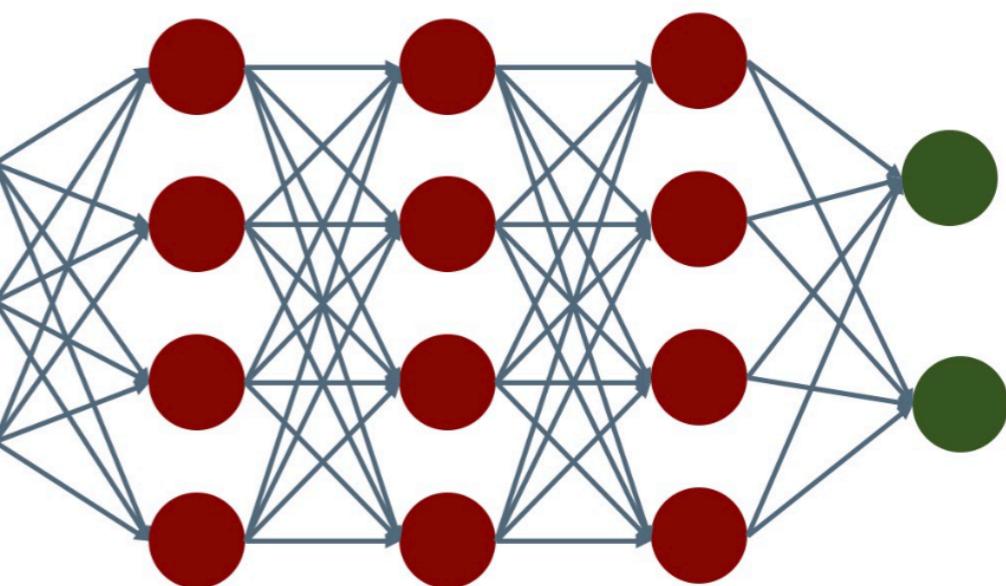
Imagen de entrada 2D

157

153

218

Vector 1D



Red neuronal totalmente conectada

- **Se pierde información espacial.**
- **1 neurona por píxel → Mucho parámetros**

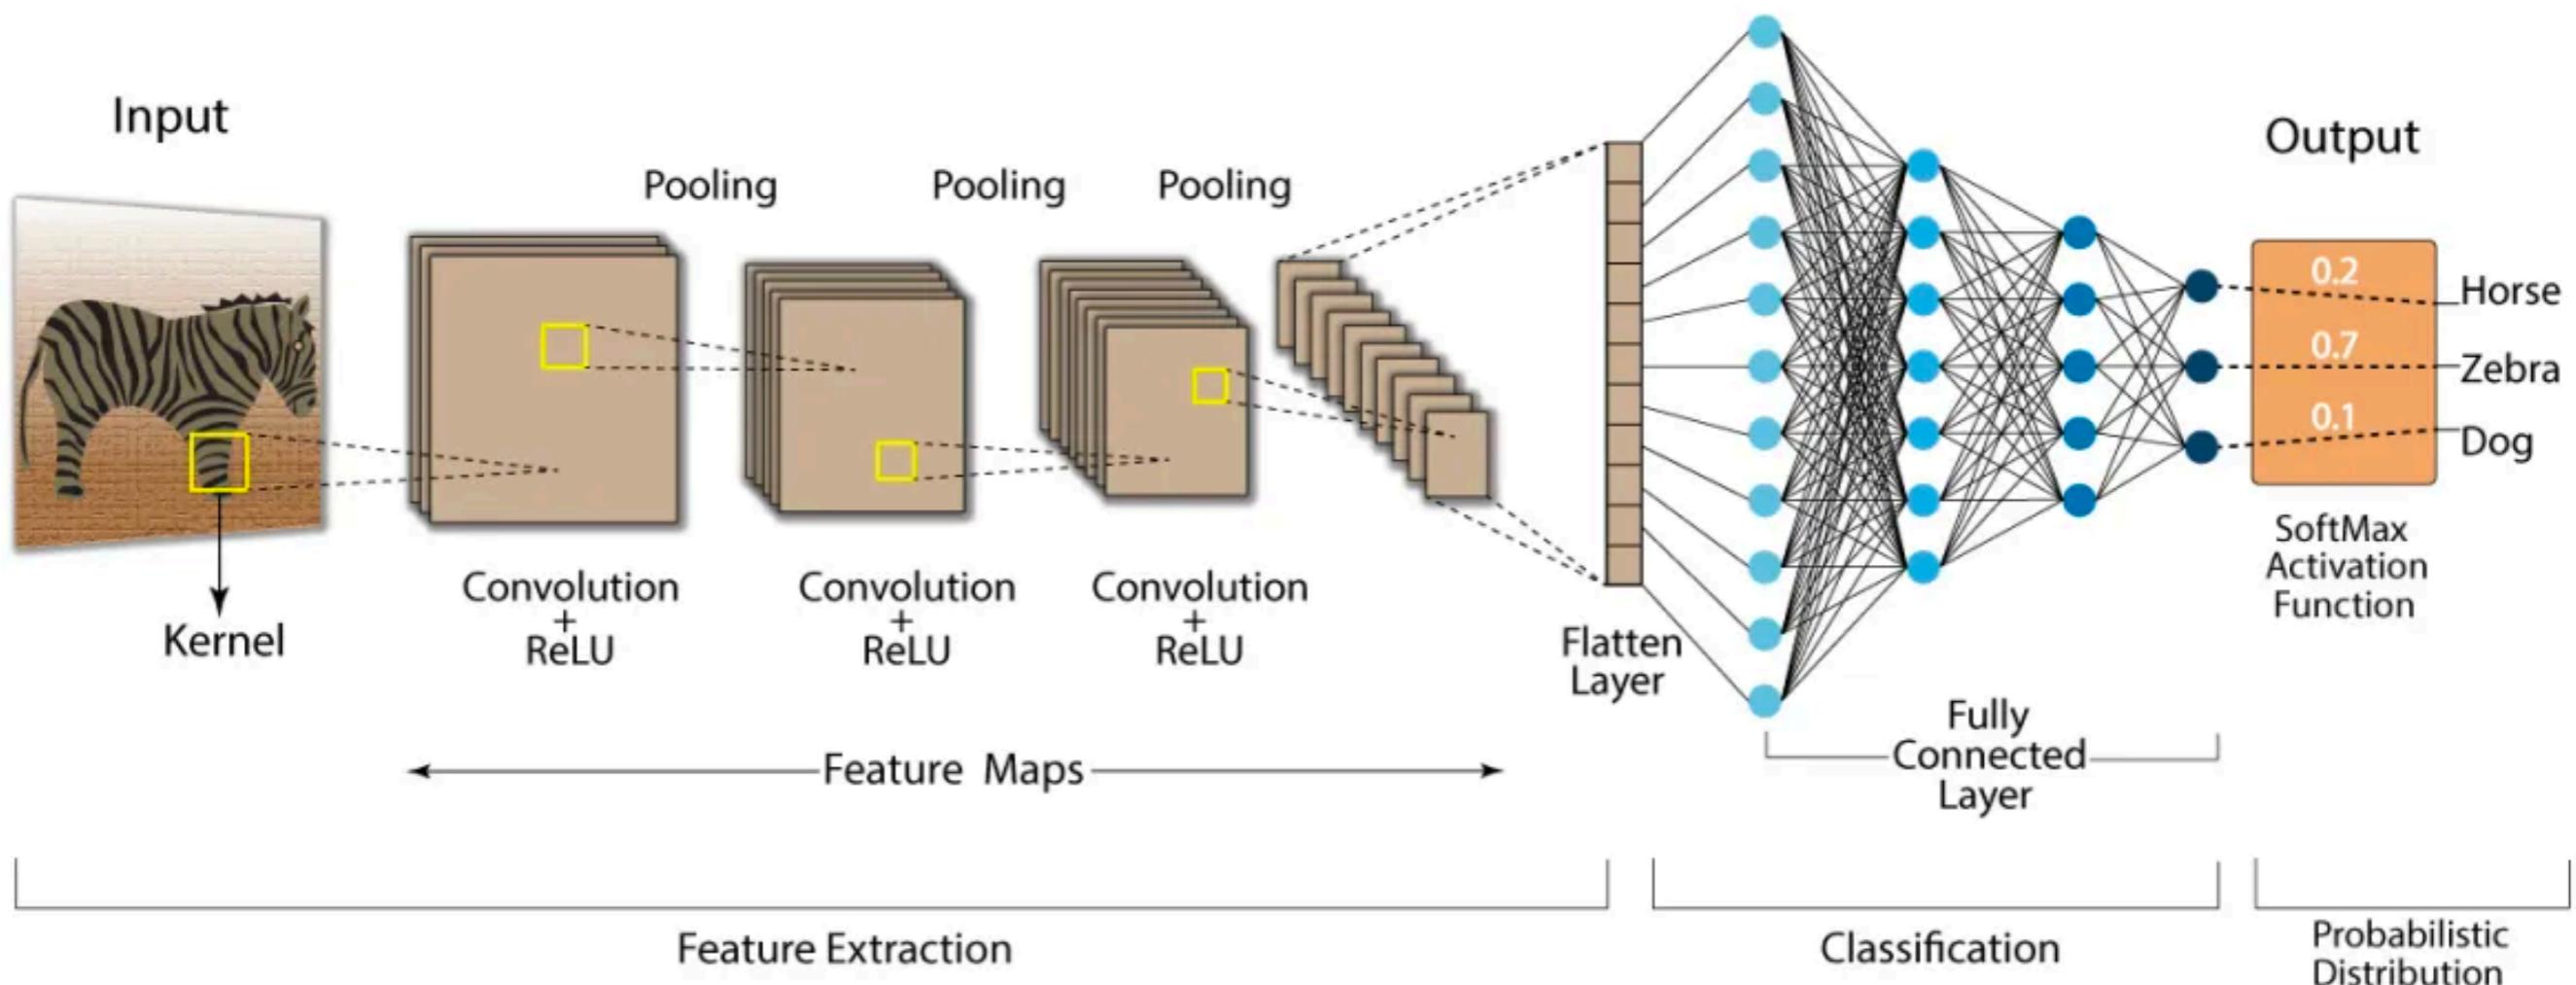
Extracción de características

157	153	174	168	186	152	129	151	172	161	155	156
155	182	163	74	75	62	83	17	110	210	180	154
180	180	50	14	84	6	10	33	48	105	159	181
206	109	5	124	131	111	120	204	166	15	55	189
194	68	137	251	237	299	299	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	105	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	35	101	255	224
190	214	173	66	103	143	95	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
196	206	123	207	177	121	123	200	175	13	96	218

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	83	17	110	210	180	154
180	180	50	14	84	6	10	33	48	105	159	181
206	109	5	124	131	111	120	204	166	15	55	189
194	68	137	251	237	299	299	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	105	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	35	101	255	224
190	214	173	66	103	143	95	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
196	206	123	207	177	121	123	200	175	13	96	218

Estructura de una CNN

Convolution Neural Network (CNN)

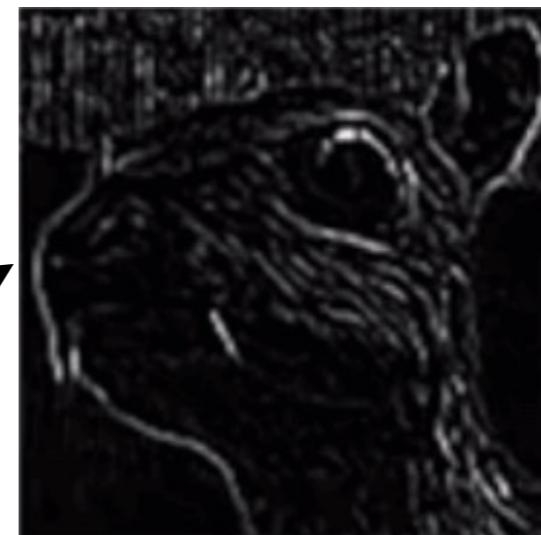


Capa convolucional

Filtro o Kernel

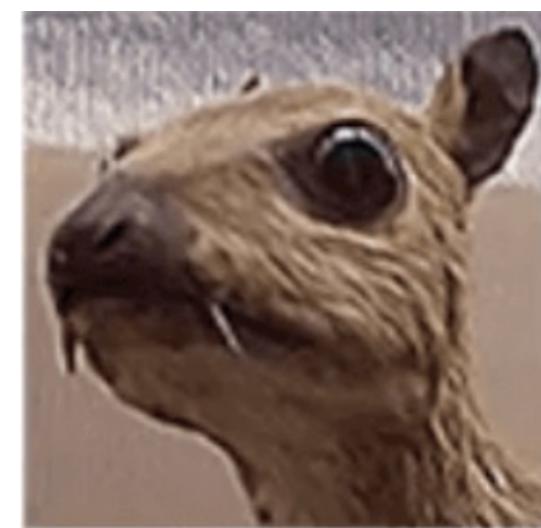


$$\begin{array}{|c|c|c|} \hline -1 & -1 & -1 \\ \hline -1 & 8 & -1 \\ \hline -1 & -1 & -1 \\ \hline \end{array}$$



Detección de bordes

$$\begin{array}{|c|c|c|} \hline 0 & -1 & 0 \\ \hline -1 & 5 & -1 \\ \hline 0 & -1 & 0 \\ \hline \end{array}$$



Perfilado

$$\begin{array}{|c|c|c|} \hline 1/9 & 1/9 & 1/9 \\ \hline 1/9 & 1/9 & 1/9 \\ \hline 1/9 & 1/9 & 1/9 \\ \hline \end{array}$$



Difuminado

Capa convolucional

Filtro o Kernel

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Dot product (Producto escalar)

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature

Capa convolucional

Filtro o Kernel

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Son estos filtros los que la CNN aprende por sí misma.

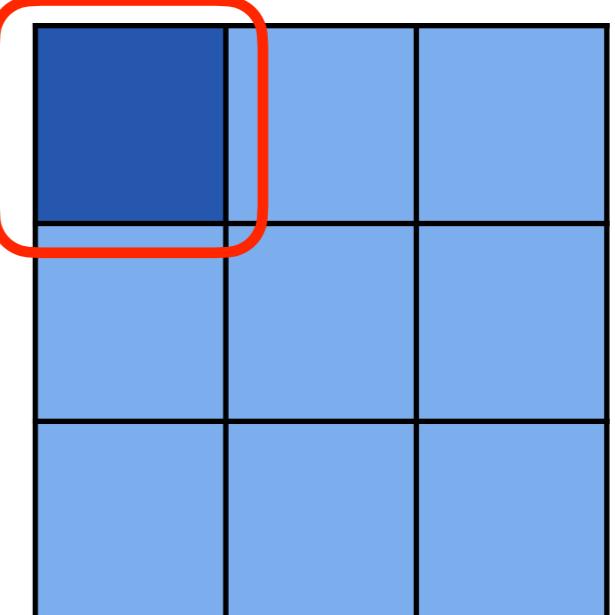
Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

W _{1,1}	W _{1,2}	W _{1,3}
W _{2,1}	W _{2,2}	W _{2,3}
W _{3,1}	W _{3,2}	W _{3,3}

Filtro o kernel



Mapa de características
(Feature map)
(o Activation map)

$$\text{Activación de la neurona } (p, q) = g\left(\sum_{i=1}^3 \sum_{j=1}^3 w_{ij} x_{i+p, j+q} + b\right)$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2		

Mapa de características
(Feature map)

$$1 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 0 * 0 + 1 * (-1) = -2$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	

Mapa de características
(Feature map)

$$1 * 1 + 1 * 0 + 0 * (-1) + 1 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) = -1$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2

Mapa de características
(Feature map)

$$1 * 1 + 0 * 0 + 0 * (-1) + 1 * 1 + 1 * 0 + 0 * (-1) + 1 * 1 + 1 * 0 + 1 * (-1) = 2$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3		

Mapa de características
(Feature map)

$$0 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 0 * 0 + 1 * (-1) + 0 * 1 + 0 * 0 + 1 * (-1) = -3$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3	-2	

Mapa de características
(Feature map)

$$1 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) = -2$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3	-2	2

Mapa de características
(Feature map)

$$1 * 1 + 1 * 0 + 0 * (-1) + 1 * 1 + 1 * 0 + 1 * (-1) + 1 * 1 + 1 * 0 + 0 * (-1) = 2$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3	-2	2
-3		

Mapa de características
(Feature map)

$$0 * 1 + 0 * 0 + 1 * (-1) + 0 * 1 + 0 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) = -3$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3	-2	2
-3	-1	

Mapa de características
(Feature map)

$$0 * 1 + 1 * 0 + 1 * (-1) + 0 * 1 + 1 * 0 + 1 * (-1) + 1 * 1 + 1 * 0 + 0 * (-1) = -1$$

Capa convolucional. Filtro o Kernel

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

-2	-1	2
-3	-2	2
-3	-1	2

Mapa de características
(Feature map)

$$1 * 1 + 1 * 0 + 1 * (-1) + 1 * 1 + 1 * 0 + 0 * (-1) + 1 * 1 + 0 * 0 + 0 * (-1) = 2$$

Capa convolucional. Stride (paso)

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

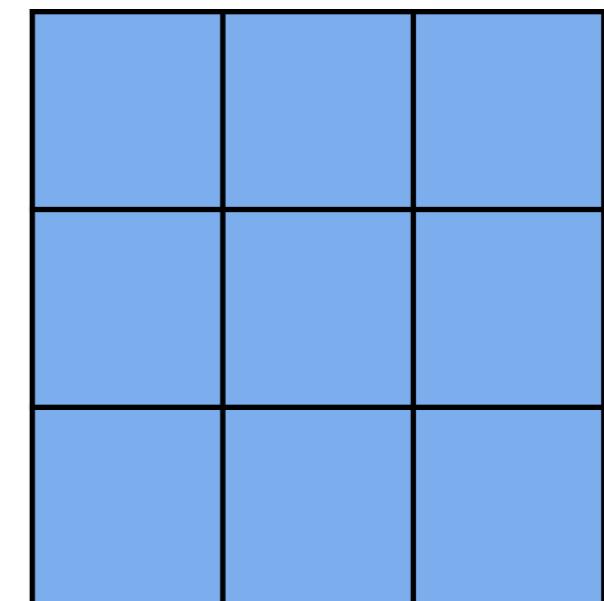
Imagen de entrada
(5 x 5)

Para stride 1

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel

3 x 3



Mapa de características
(3 x 3)

Capa convolucional. Stride (paso)

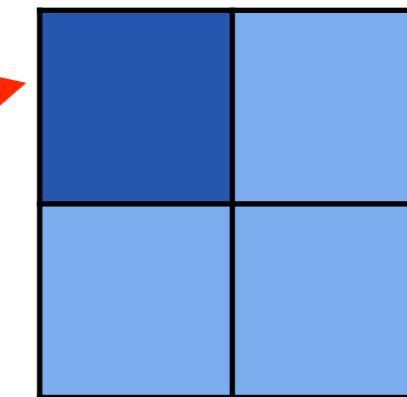
1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada
(5 x 5)

Para stride 2

1	0	-1
1	0	-1
1	0	-1

Filtro o kernel
3 x 3



Mapa de características
(2 x 2)

Capa convolucional. Stride (paso)

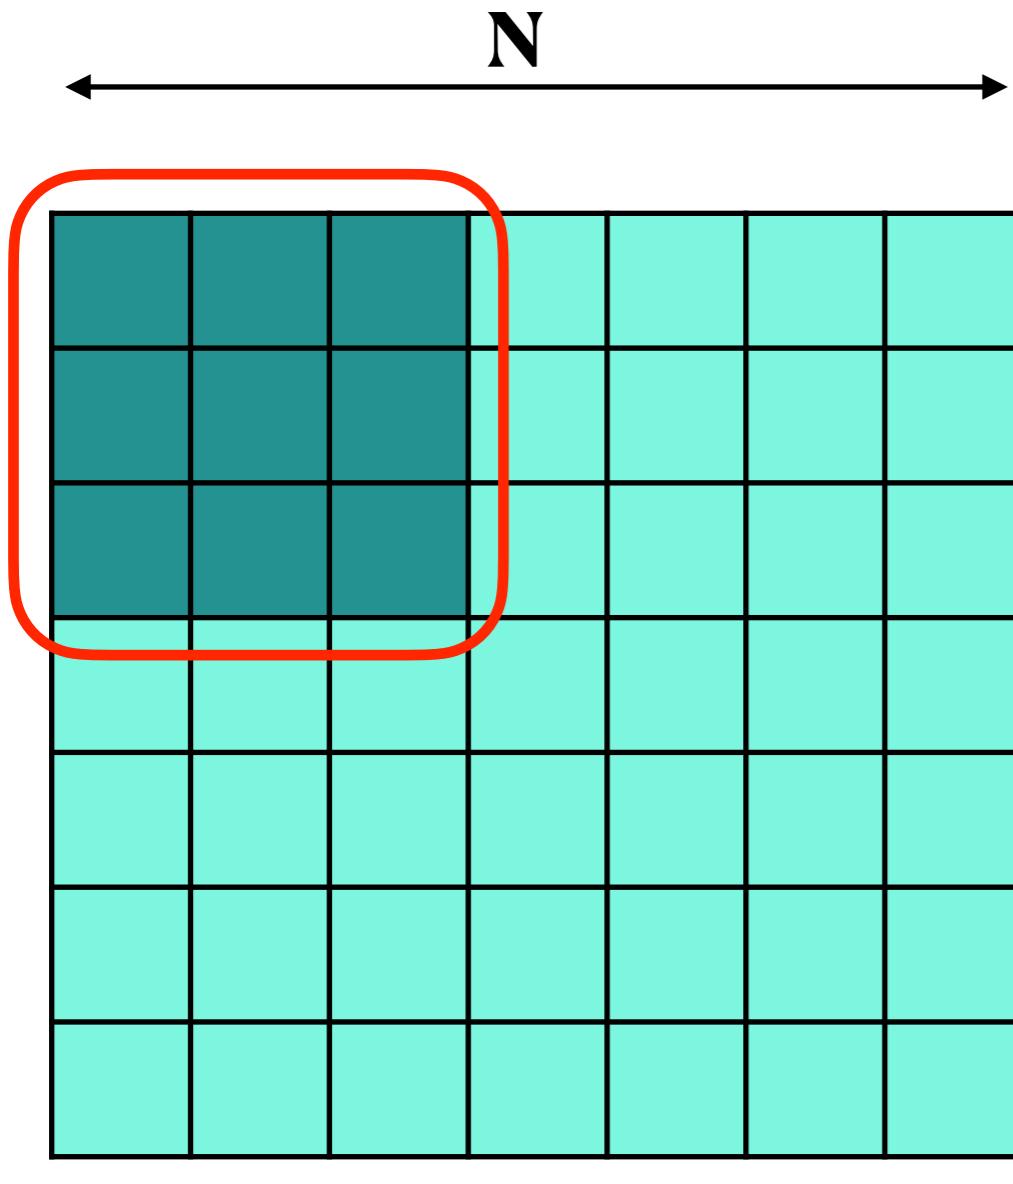
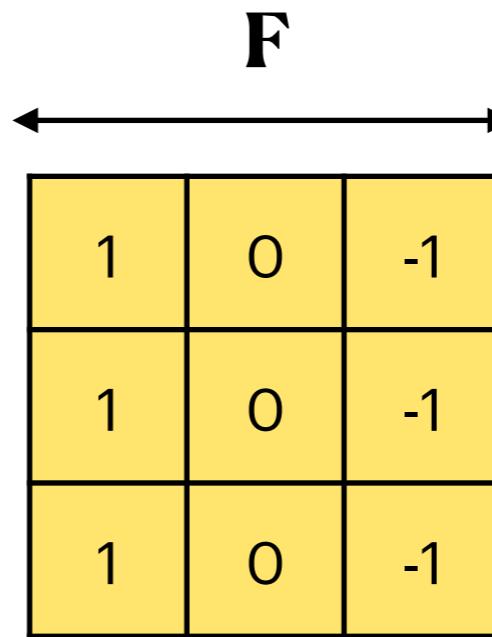


Imagen de entrada

(**7 x 7**)



Filtro o kerner

3 x 3

Tamaño de feature map:

$$(\mathbf{N} - \mathbf{F}) / \text{stride} + 1$$

e.g. $\mathbf{N} = 7, \mathbf{F} = 3$

stride = 1 $\rightarrow (7-3)/1 + 1 = 5$

stride = 2 $\rightarrow (7-3)/2 + 1 = 3$

stride = 3 $\rightarrow (7-3)/3 + 1 = 2,33$

Capa convolucional. Padding

Margen que se añade a la imagen de entrada para **controlar el tamaño** del mapa de características que se genera. Hay que evitar reducir el tamaño de la imagen muy rápido.

Necesario para capturar información de los **bordes de la imagen**.

0	0	0	0	0	0	0	0
0	1	1	1	0	0	0	0
0	0	1	1	1	0	0	0
0	0	0	1	1	1	1	0
0	0	0	1	1	0	0	0
0	0	1	1	0	0	0	0
0	0	0	0	0	0	0	0

Imagen de entrada

Padding = 1

W _{1,1}	W _{1,2}	W _{1,3}
W _{2,1}	W _{2,2}	W _{2,3}
W _{3,1}	W _{3,2}	W _{3,3}

Filtro o kernel

Mapa de características
(Feature map)

Capa convolucional. Padding

Padding same -> Padding necesario para que el mapa de características tenga el mismo tamaño que el original

0	0	0	0	0	0	0
0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	0	1	1	1	0
0	0	0	1	1	0	0
0	0	1	1	0	0	0
0	0	0	0	0	0	0

Padding=1

$W_{1,1}$	$W_{1,2}$	$W_{1,3}$
$W_{2,1}$	$W_{2,2}$	$W_{2,3}$
$W_{3,1}$	$W_{3,2}$	$W_{3,3}$

Filtro o kernel

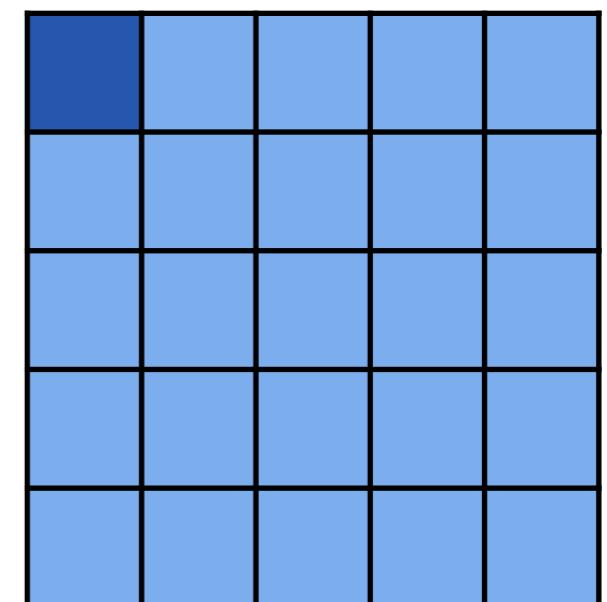


Imagen de entrada

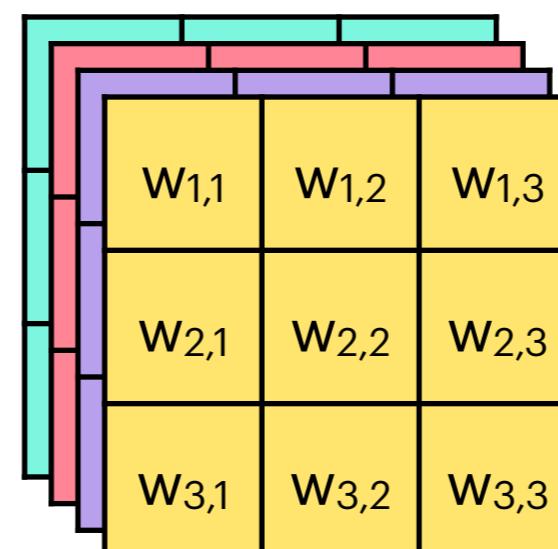
**Mapa de características
(Feature map)**

Capa convolucional. Filtros o Kernels

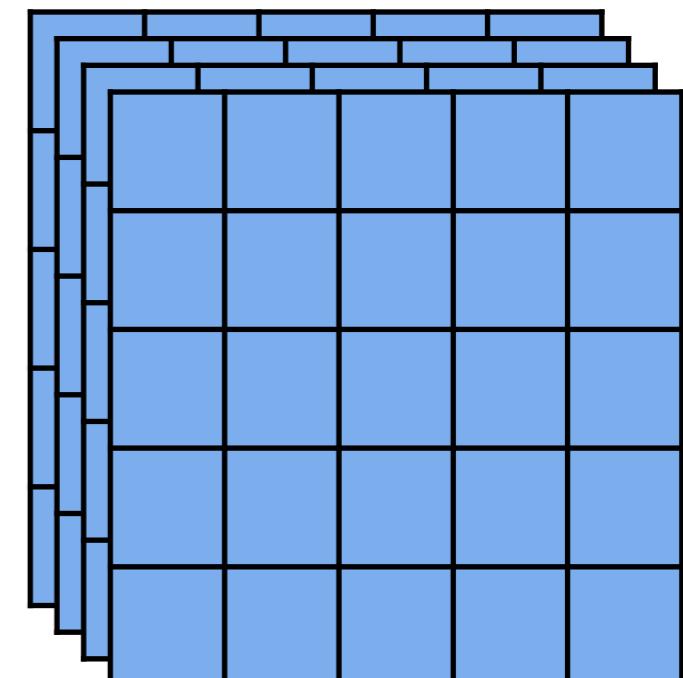
Normalmente tendremos **múltiples filtros**. Cada uno de ellos se especializará en detectar un tipo de **característica**.

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen de entrada



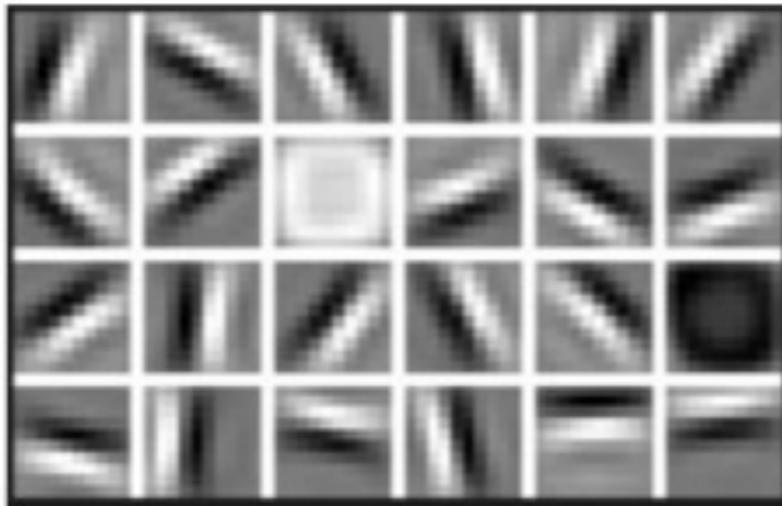
Filtros o kernels



Mapas de características
(Feature maps)

Capa convolucional. Filtros o Kernels

24 filtros de la 1^a capa
convolucional



40 filtros de la 2^a capa
convolucional

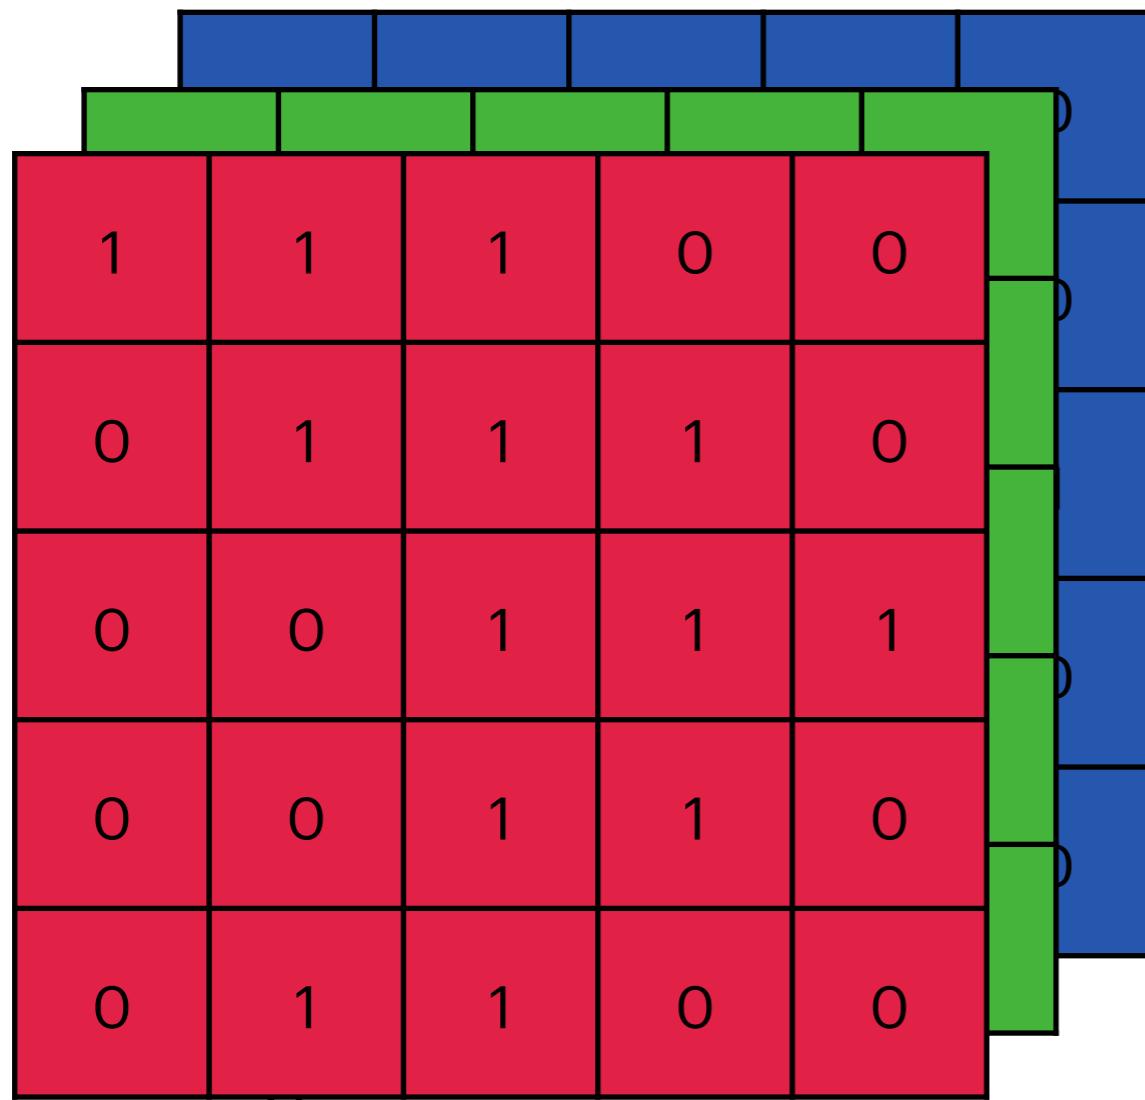


24 filtros de la 3^a capa
convolucional



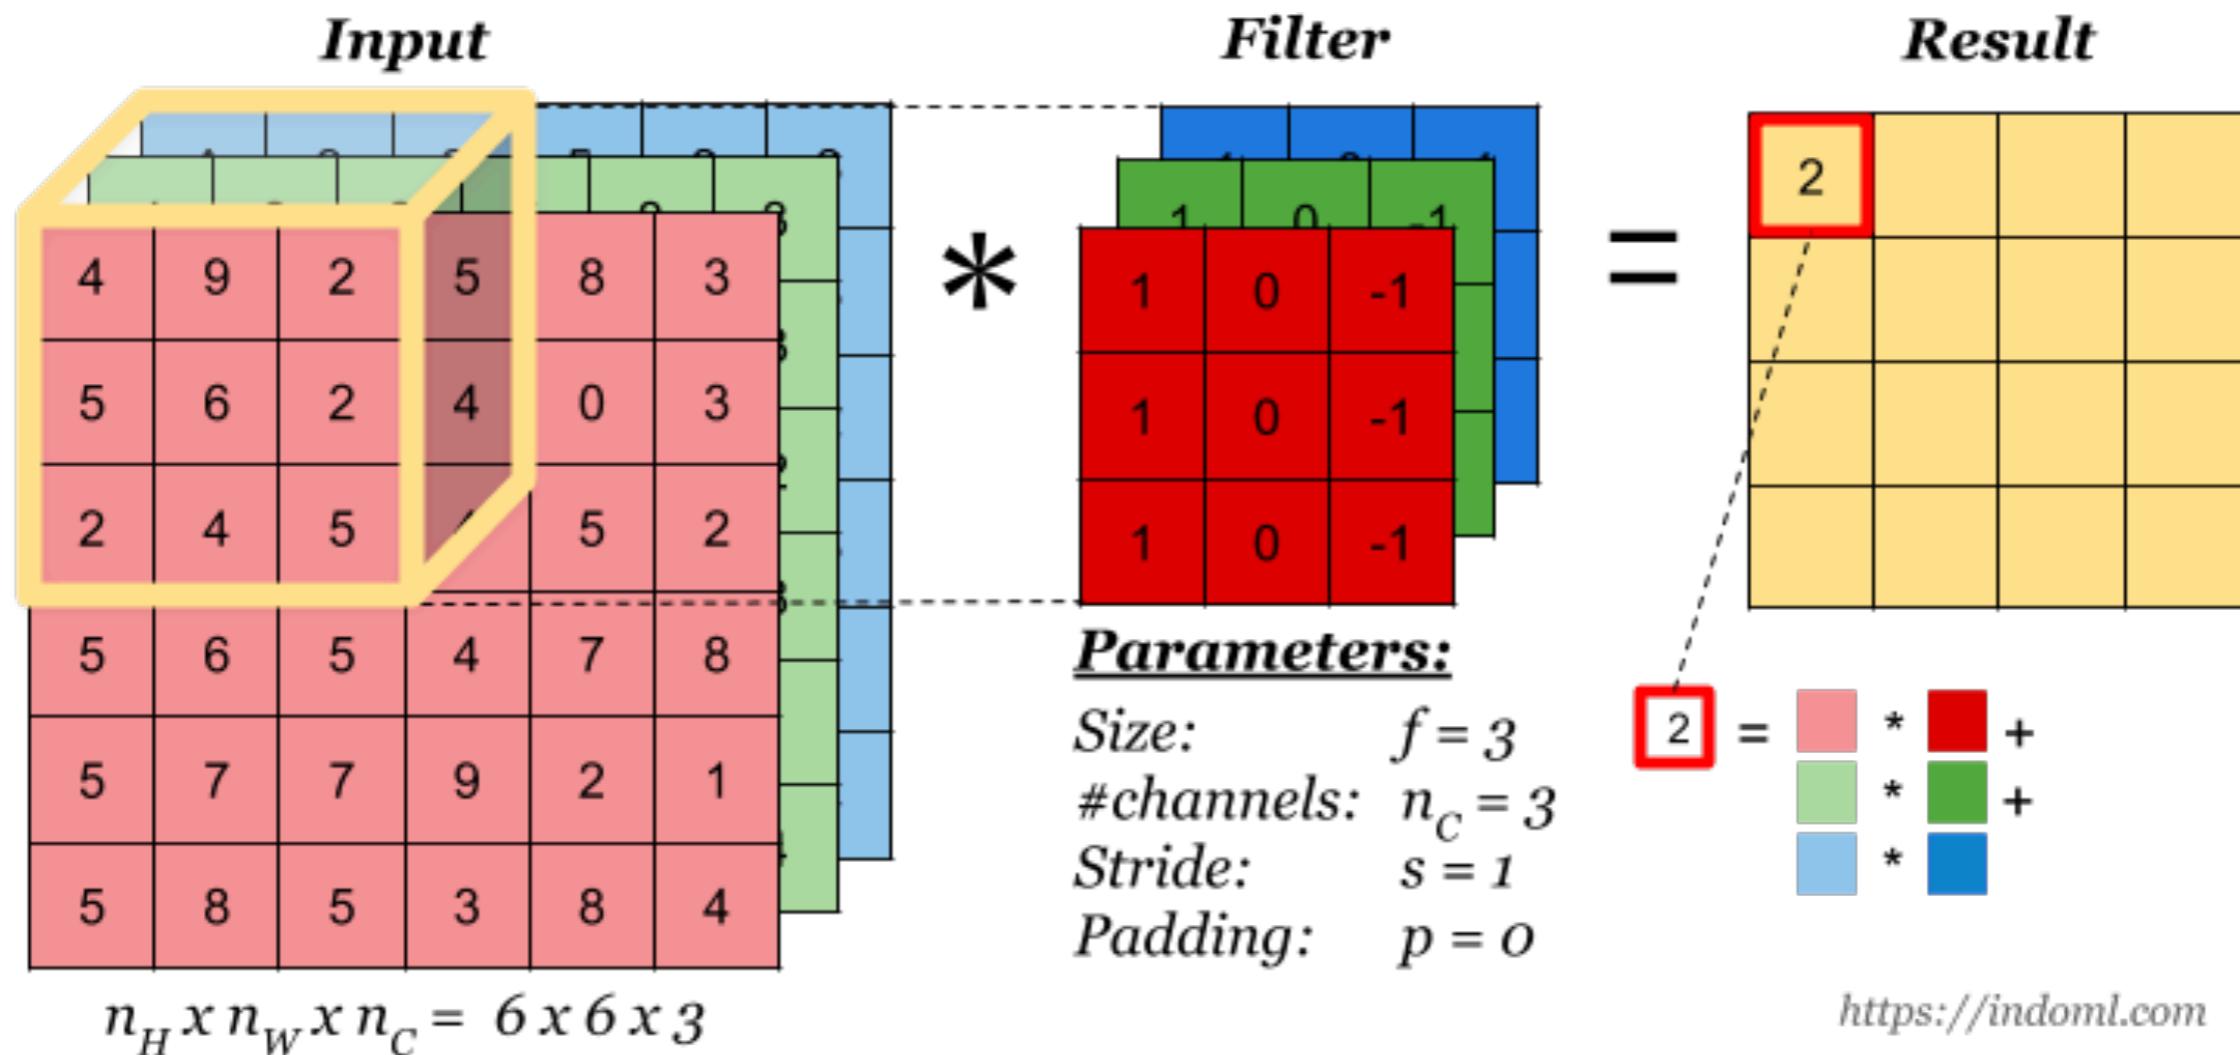
Capa convolucional. Filtros o Kernels

La imagen de entrada suele tener 1 (escala de grises) o 3 canales (imagen en color).



Capa convolucional. Filtros o Kernels

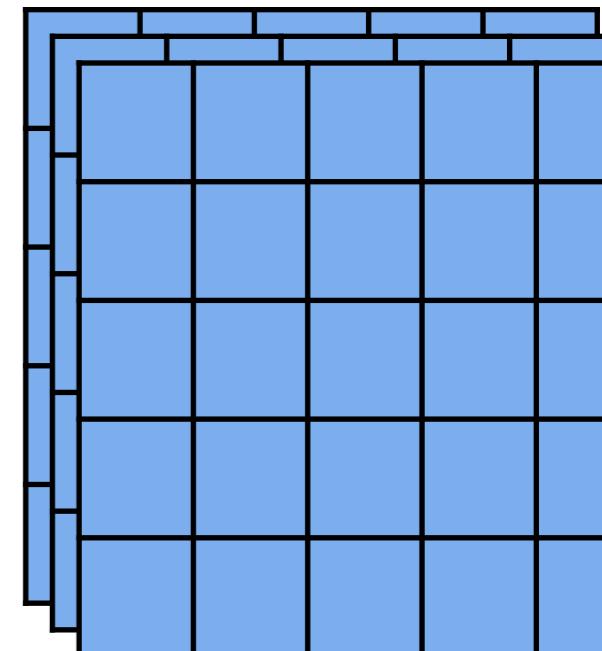
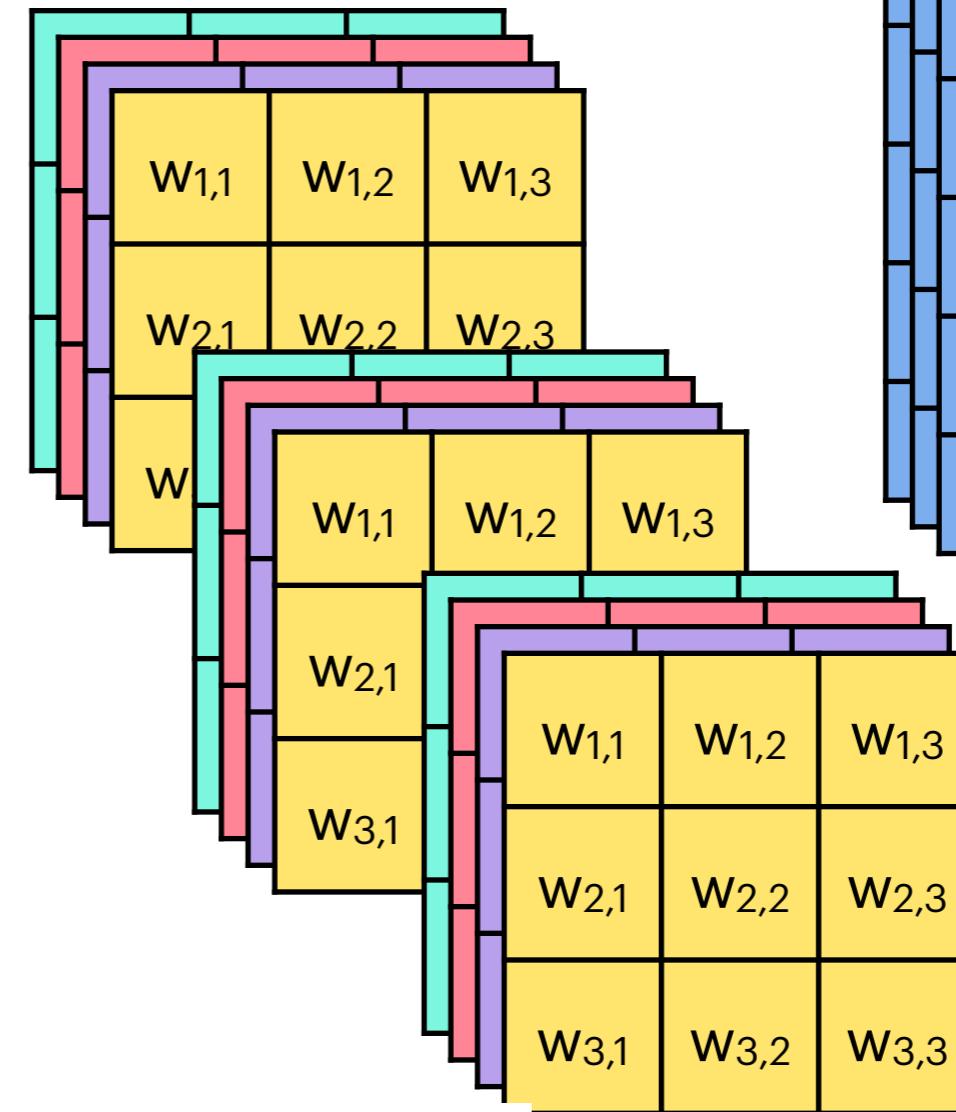
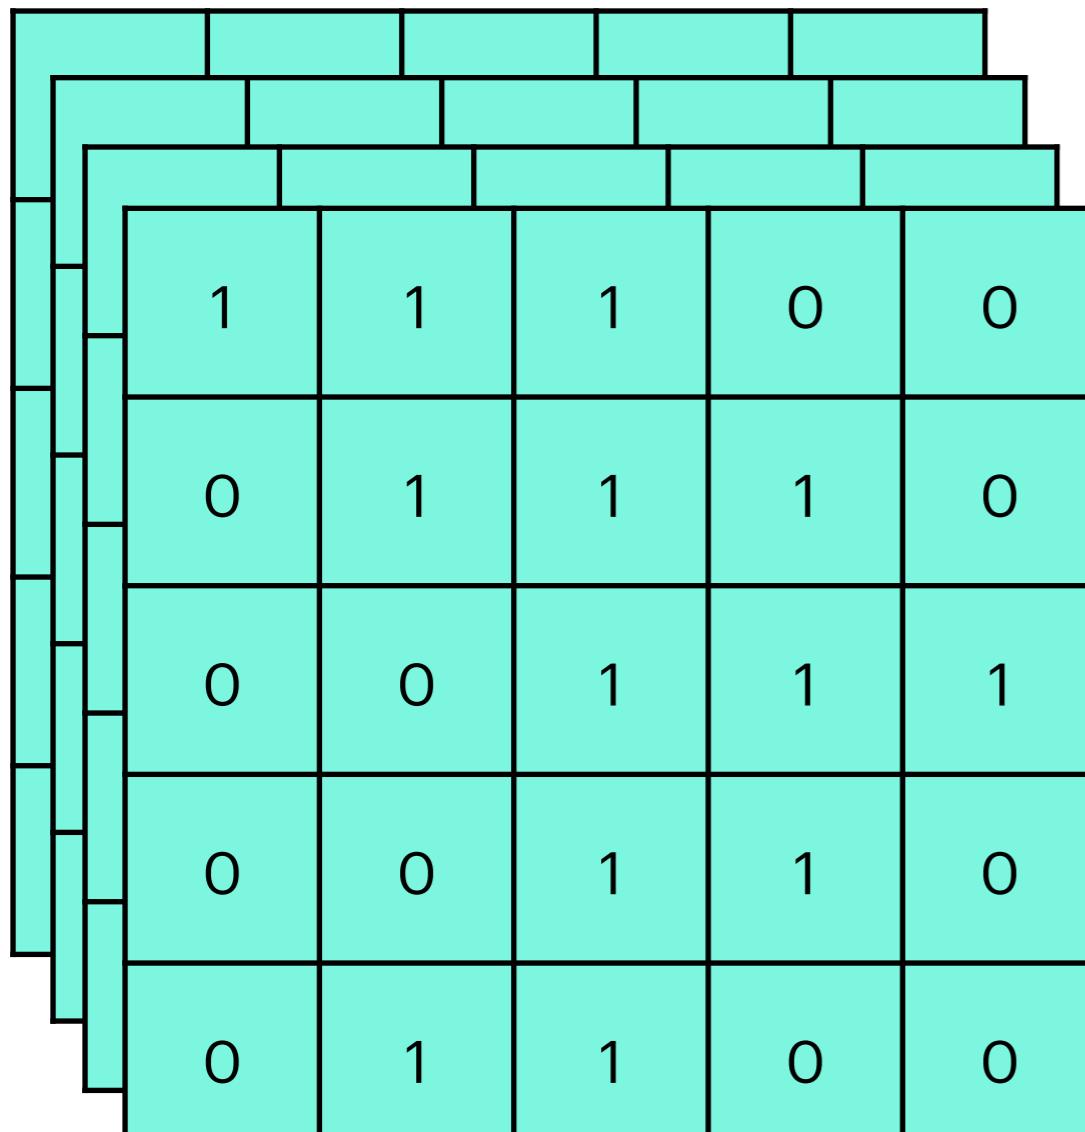
En el caso de 3 canales, aplicamos una convolución 2D sobre una matriz 3D.



El filtro tiene 3 dimensiones. La salida es un mapa de características de sólo 2 dimensiones. Cada celda se calcula como la suma ponderada de aplicar cada uno de los 3 filtros.

Capa convolucional. Filtros o Kernels

De manera similar, cuando tenemos varios mapas de características de entrada, los filtros tendrán una tercera dimensión con el mismo número de capas:



Salida de 3
mapas de
características

Ejemplo de 3 filtros con 4 capas cada uno para 4
mapas de características de entrada

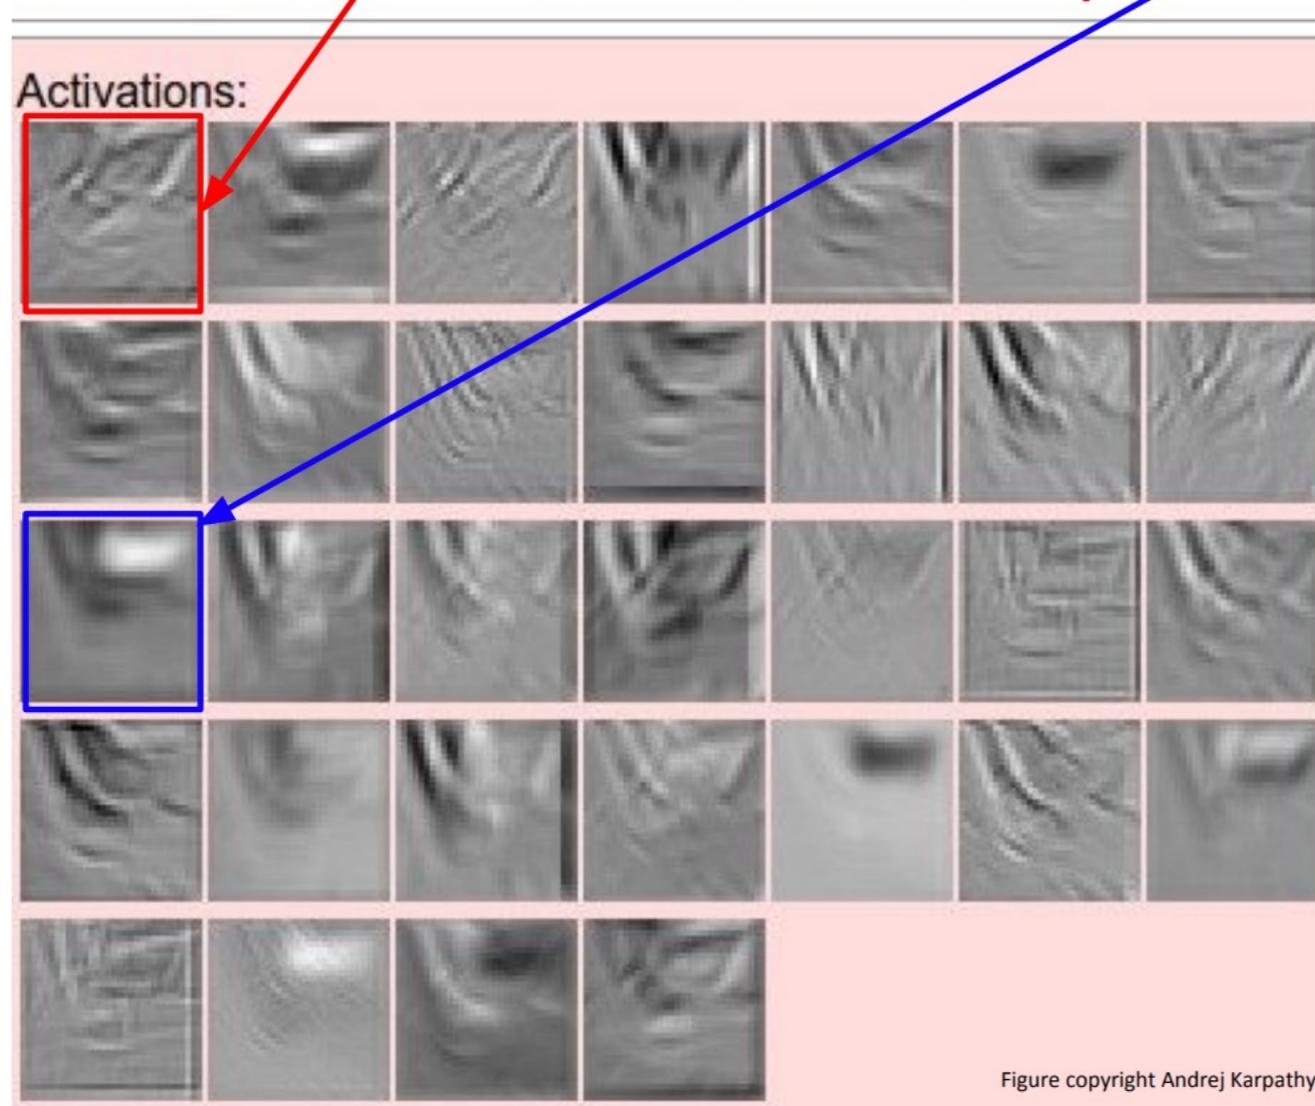
Capa convolucional. Hiperparámetros

Input Image



one filter =>
one activation map

example 5x5 filters
(32 total)



Feature maps (o Activations)

Capa convolucional. Hiperparámetros

Hiperparámetros a definir al crear una capa convolucional:

- Tamaño del filtro (F)
- Número de filtros (K)
- Stride (S)
- Padding(P)

Tamaño de la salida (mapa de características) (N_s, N_s, K):

$$N_s = \left\lceil \frac{N + 2P - F}{S} \right\rceil + 1$$

Capa convolucional. Hiperparámetros

Hiperparámetros a definir al crear una capa convolucional:

- Tamaño del filtro (F)
- Número de filtros (K)
- Stride (S)
- Padding(P)

Tamaño de la salida (mapa de características) (N_s, N_s, K):

$$N_s = \left\lceil \frac{N + 2P - F}{S} \right\rceil + 1$$

Ejemplo:

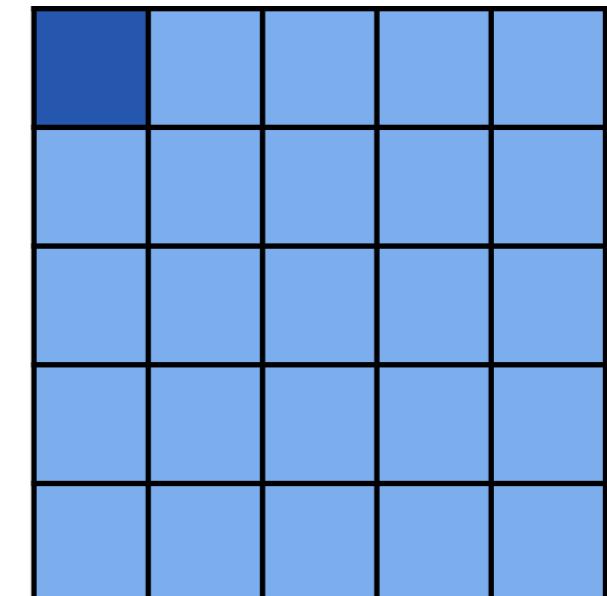
0	0	0	0	0	0	0
0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	0	1	1	1	0
0	0	0	1	1	0	0
0	0	1	1	0	0	0
0	0	0	0	0	0	0

↑
Padding=1

$$\left[\frac{5 + 2 * 1 - 3}{1} \right] + 1 = 5$$

W _{1,1}	W _{1,2}	W _{1,3}
W _{2,1}	W _{2,2}	W _{2,3}
W _{3,1}	W _{3,2}	W _{3,3}

Filtro o kernel



Mapa de características
(Feature map)

Imagen de entrada

Capa convolucional. Hiperparámetros

Hiperparámetros a definir al crear una capa convolucional:

- Tamaño del filtro (**F**)
- Número de filtros (**K**)
- Stride (**S**)
- Padding(**P**)

Tamaño de la salida (mapa de características) (**N_s, N_s, K**):

$$N_S = \left[\frac{N + 2P - F}{S} \right] + 1$$

The diagram illustrates the formula for calculating the output size N_S . It shows a horizontal bar divided into four segments: the first segment is labeled **K** (number of filters), the second is **F** (kernel size), the third is **S** (stride), and the fourth is **P** (padding). Arrows point from each label to its corresponding part of the bar.

```
conv = Conv2D(filters=64, kernel_size=(3, 3), strides=(1,1), padding='same')
```



Configuraciones comunes:

$K \rightarrow$ Múltiplos de 2

$F = 3, S = 1, P = 1$

$F = 5, S = 1, P = 2$

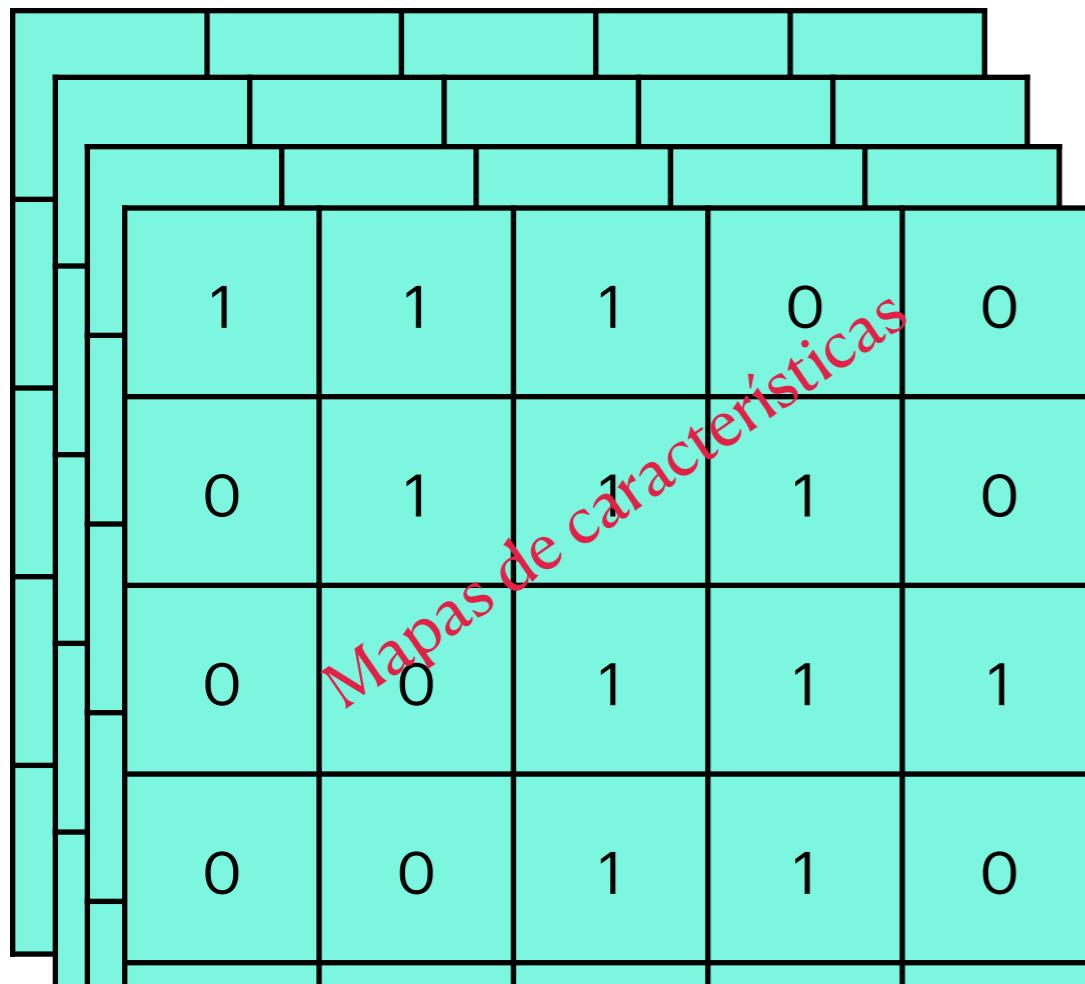
$F = 5, S = 2, P = \text{same}$

$F = 1, S = 1, P = 0$

Capa convolucional. Nº de parámetros

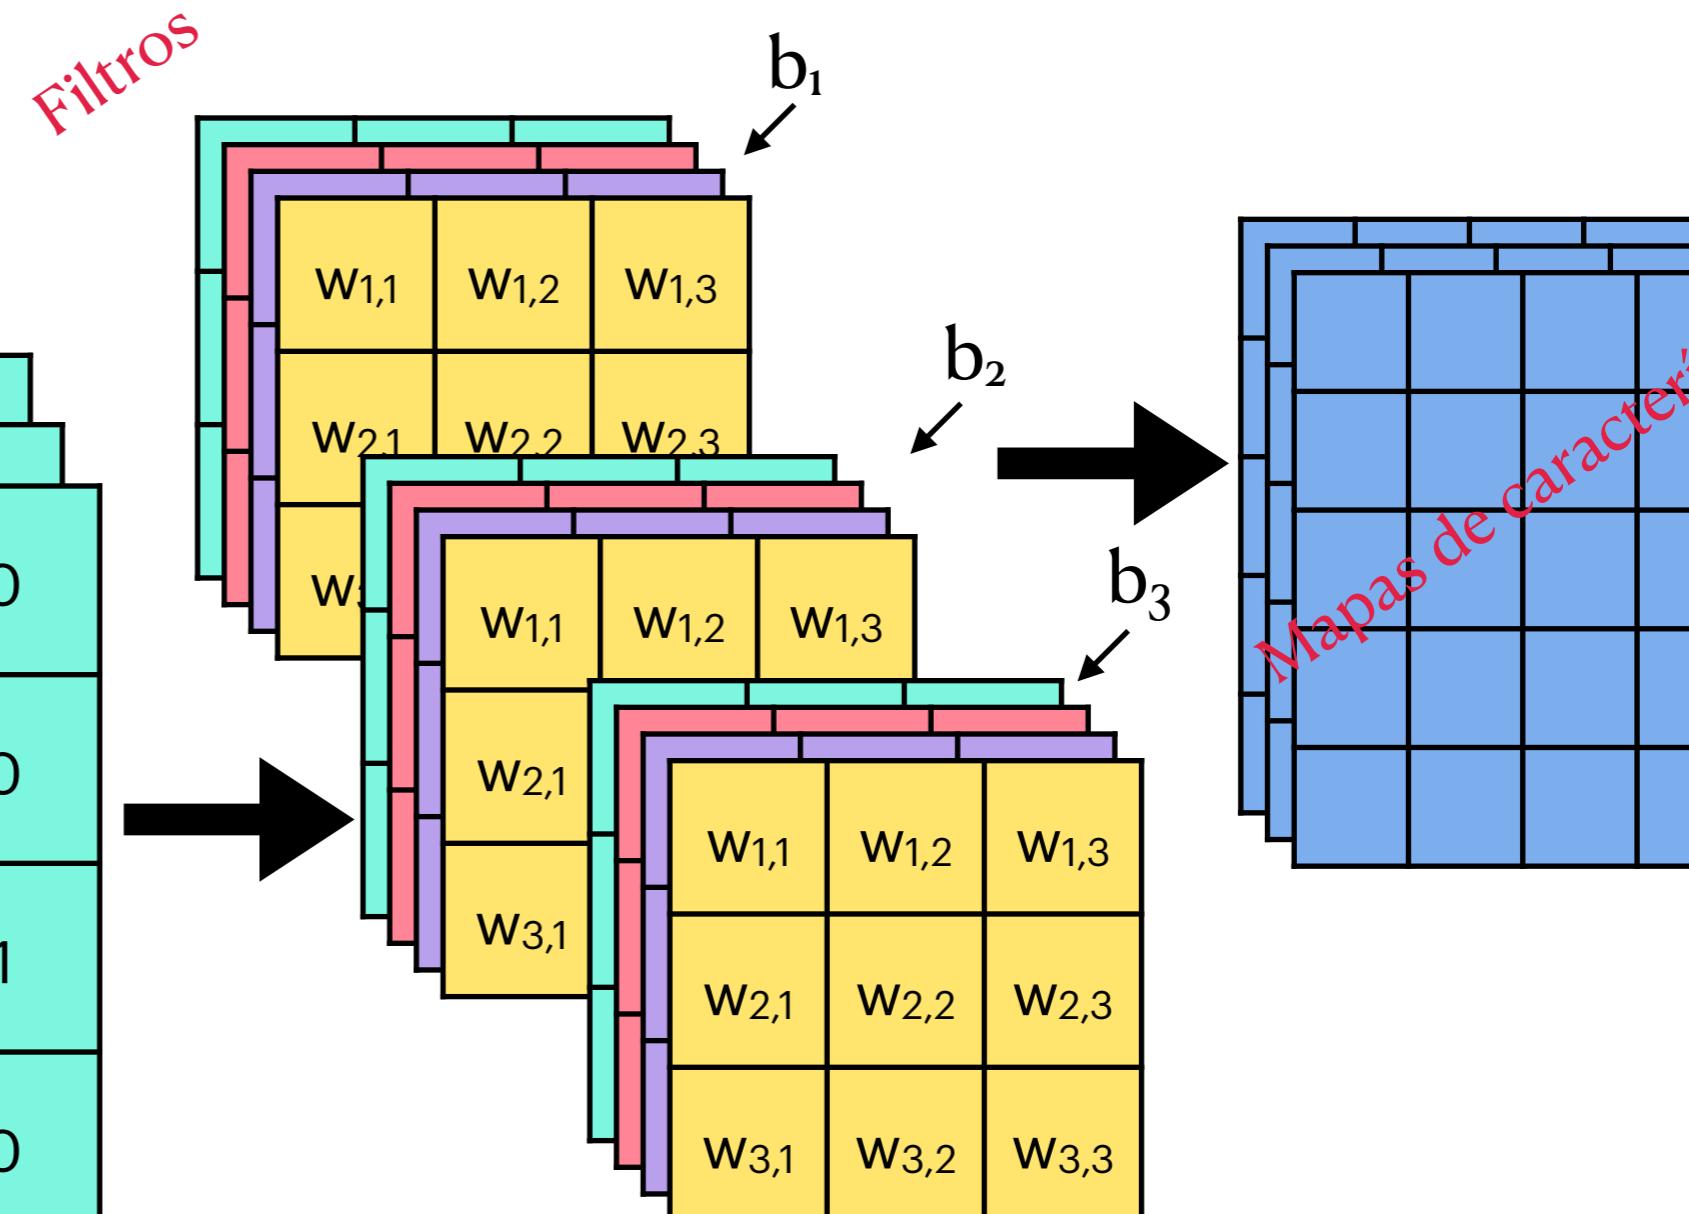
Los parámetros de una capa convolucional son los pesos que de los filtros + el bias

- Tamaño del filtro (**F**)
- Número mapas de características de entrada (**M**)
- Nº de filtros (**K**)



$$\text{params} = (F * F * M + 1) * K$$

$$\text{params} = (3 * 3 * 4 + 1) * 3 = 111$$

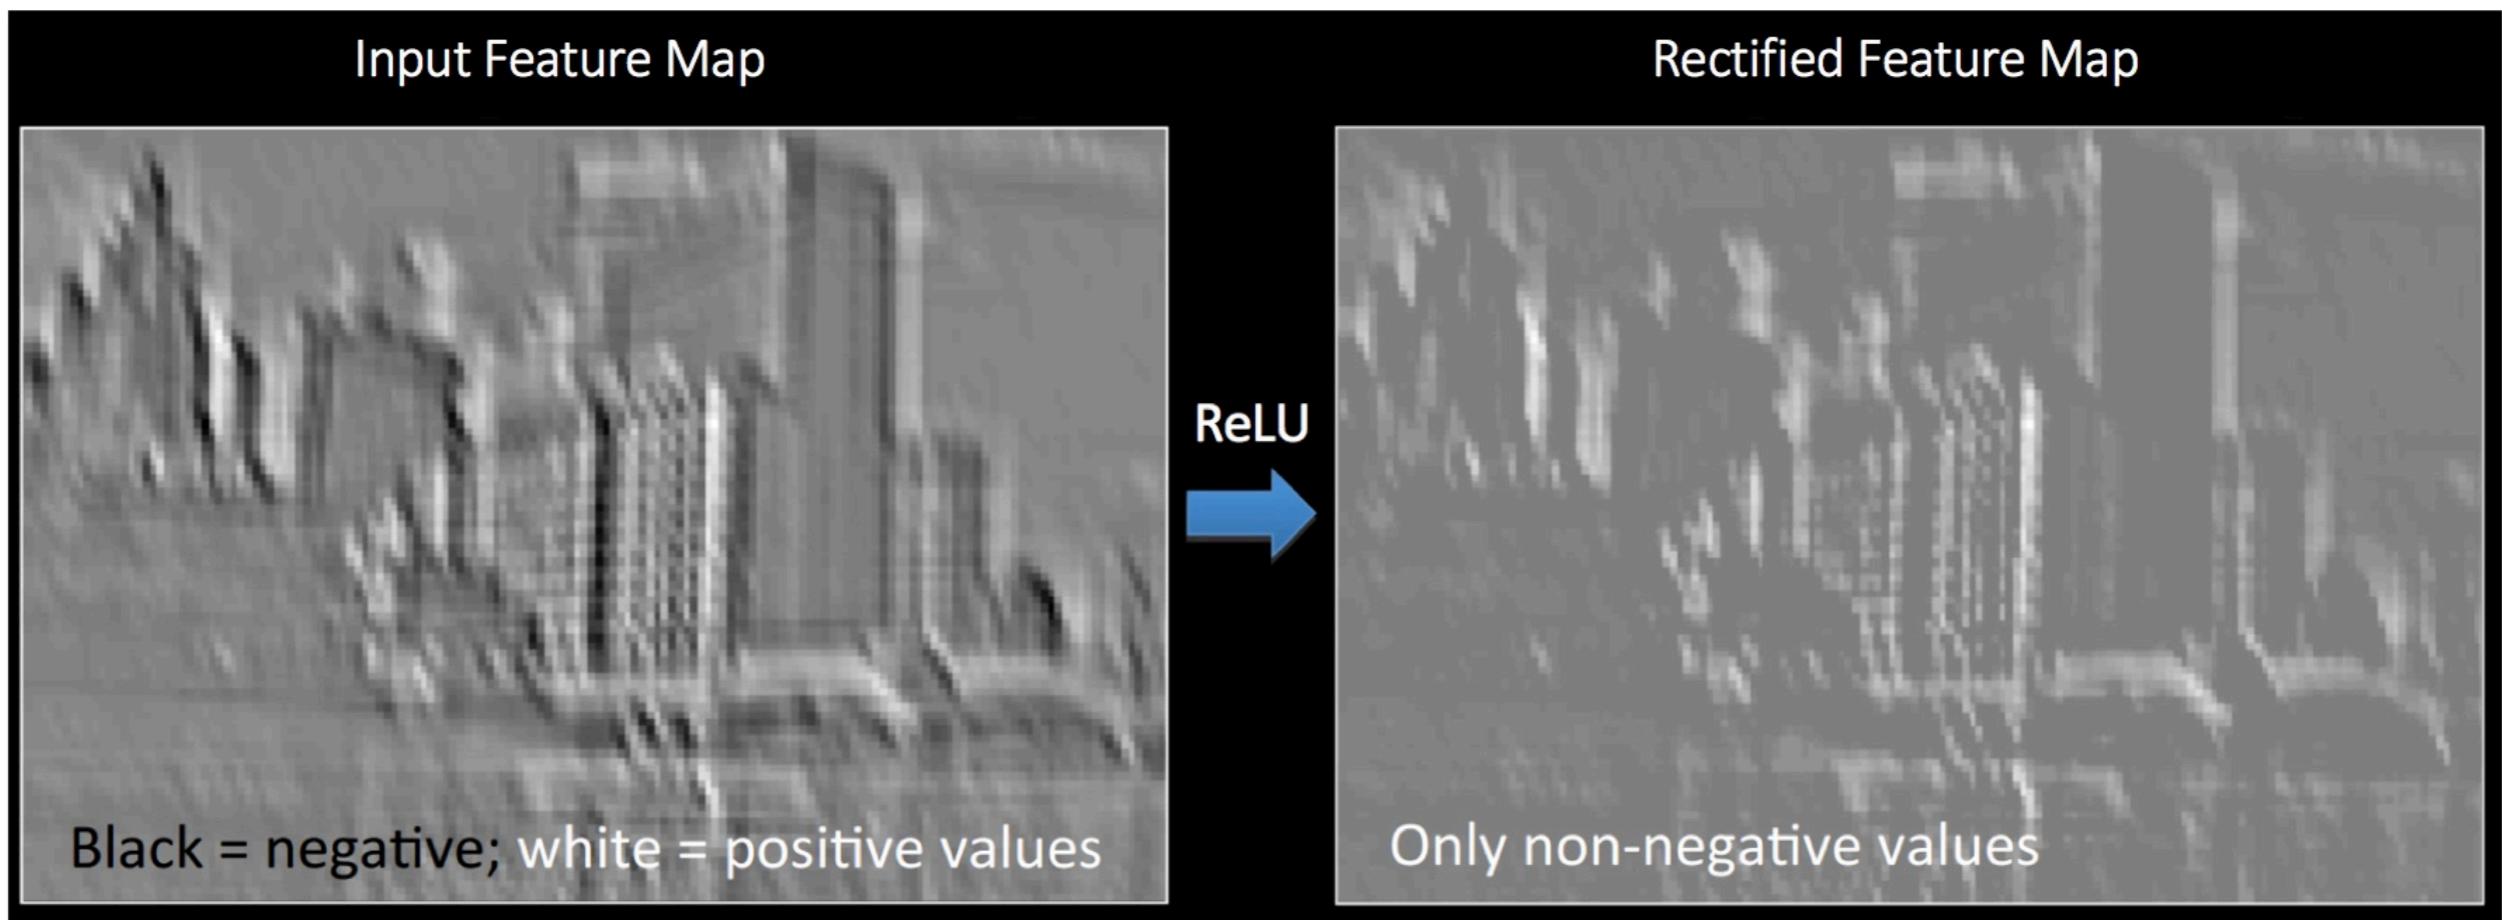


Capa convolucional. Función de activación

- Se introducen no linealidades
- Se aplica tras cada filtro convolucional
- La más común es ReLU (Rectified Linear Unit). Reemplaza todos los píxeles negativos por cero.

```
act = Activation('relu')(conv)
```

K Keras



Capa de pooling o subsampling.

Capa para **reducir el tamaño** de los mapas de características preservando la información más importante.

Reduciendo el tamaño de la capa, aún se mantienen elementos estructurales importantes, sin perder el detalle fino que puede no sea útil para la clasificación.

2	8	4	4
1	9	0	6
3	7	8	2
5	9	4	6

Imagen de entrada

Agrupación
de media

5	7
12	5

Imagen de salida

Agrupación
de máxima

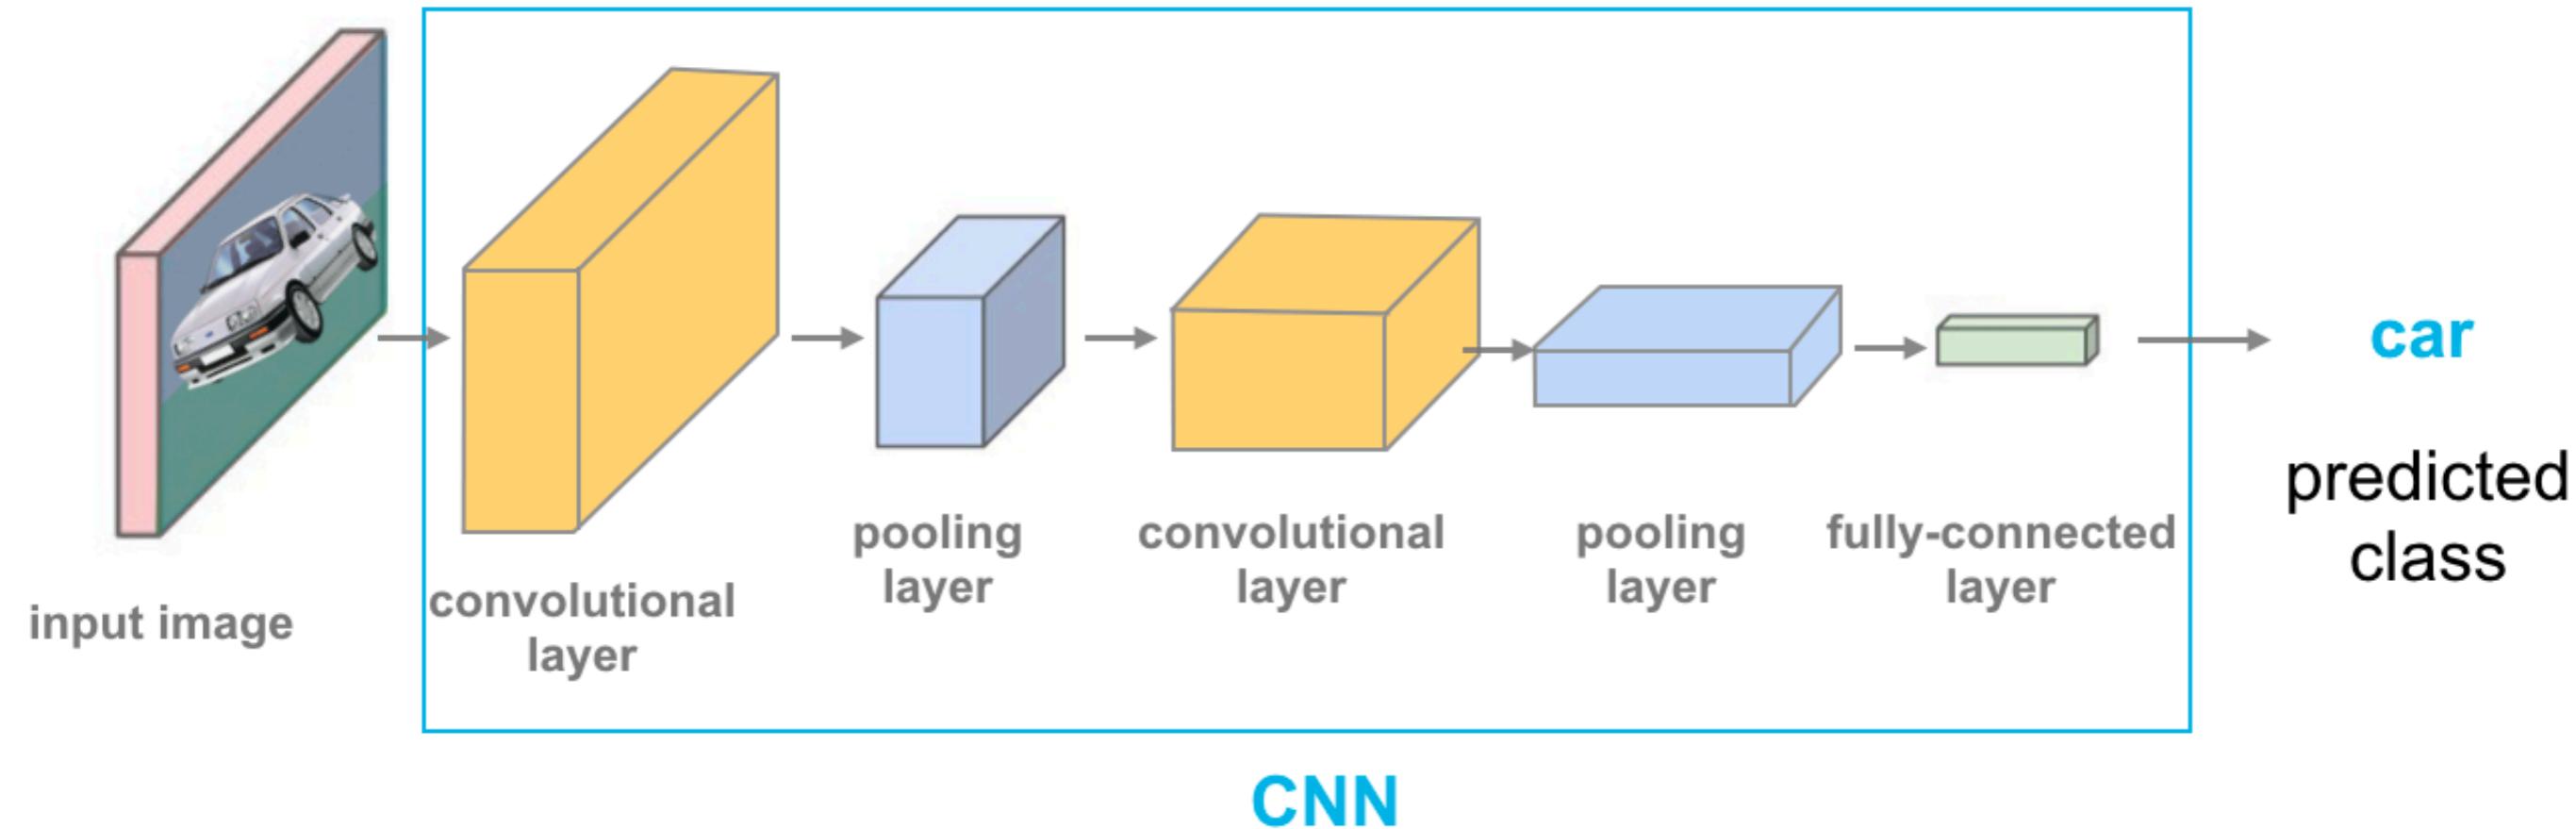
9	6
9	8

Imagen de salida



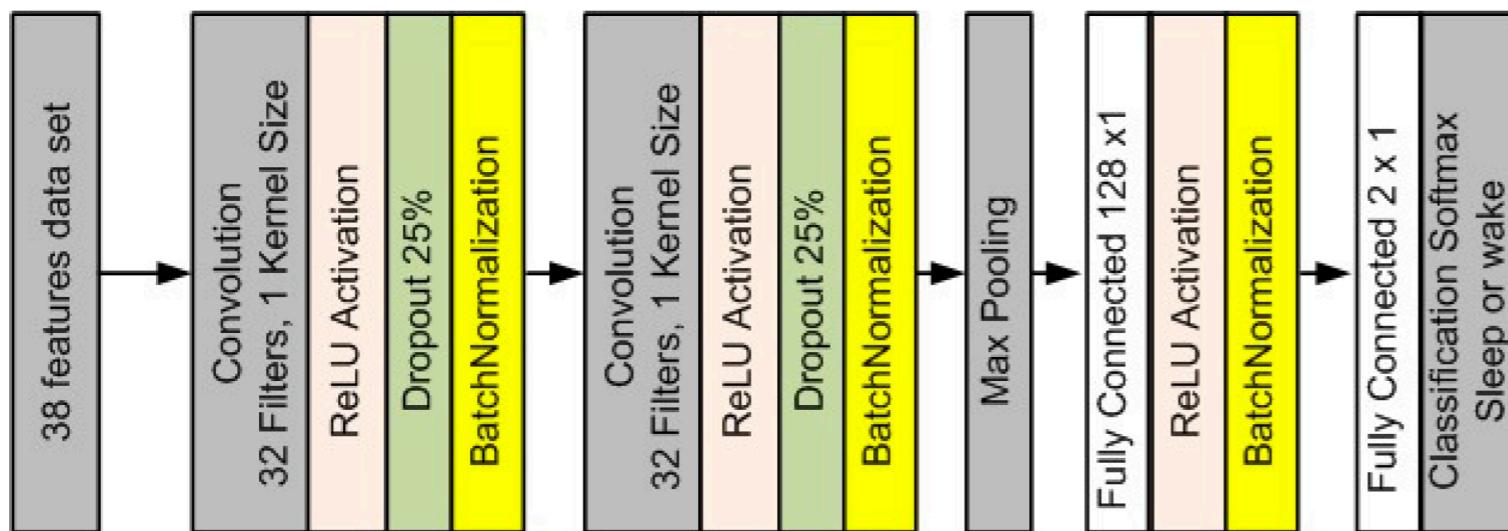
```
pool = MaxPooling2D(pool_size=(2, 2), strides=(2, 2))(act)
```

Capa de pooling o subsampling.



Capa de Batch Normalization.

Funciona de manera similar a las redes densamente conectadas, pero en este caso, en lugar de hacerlo sobre un mini-batch, se realiza sobre toda la capa ya que se aplica el mismo filtro a todos los valores de entrada.

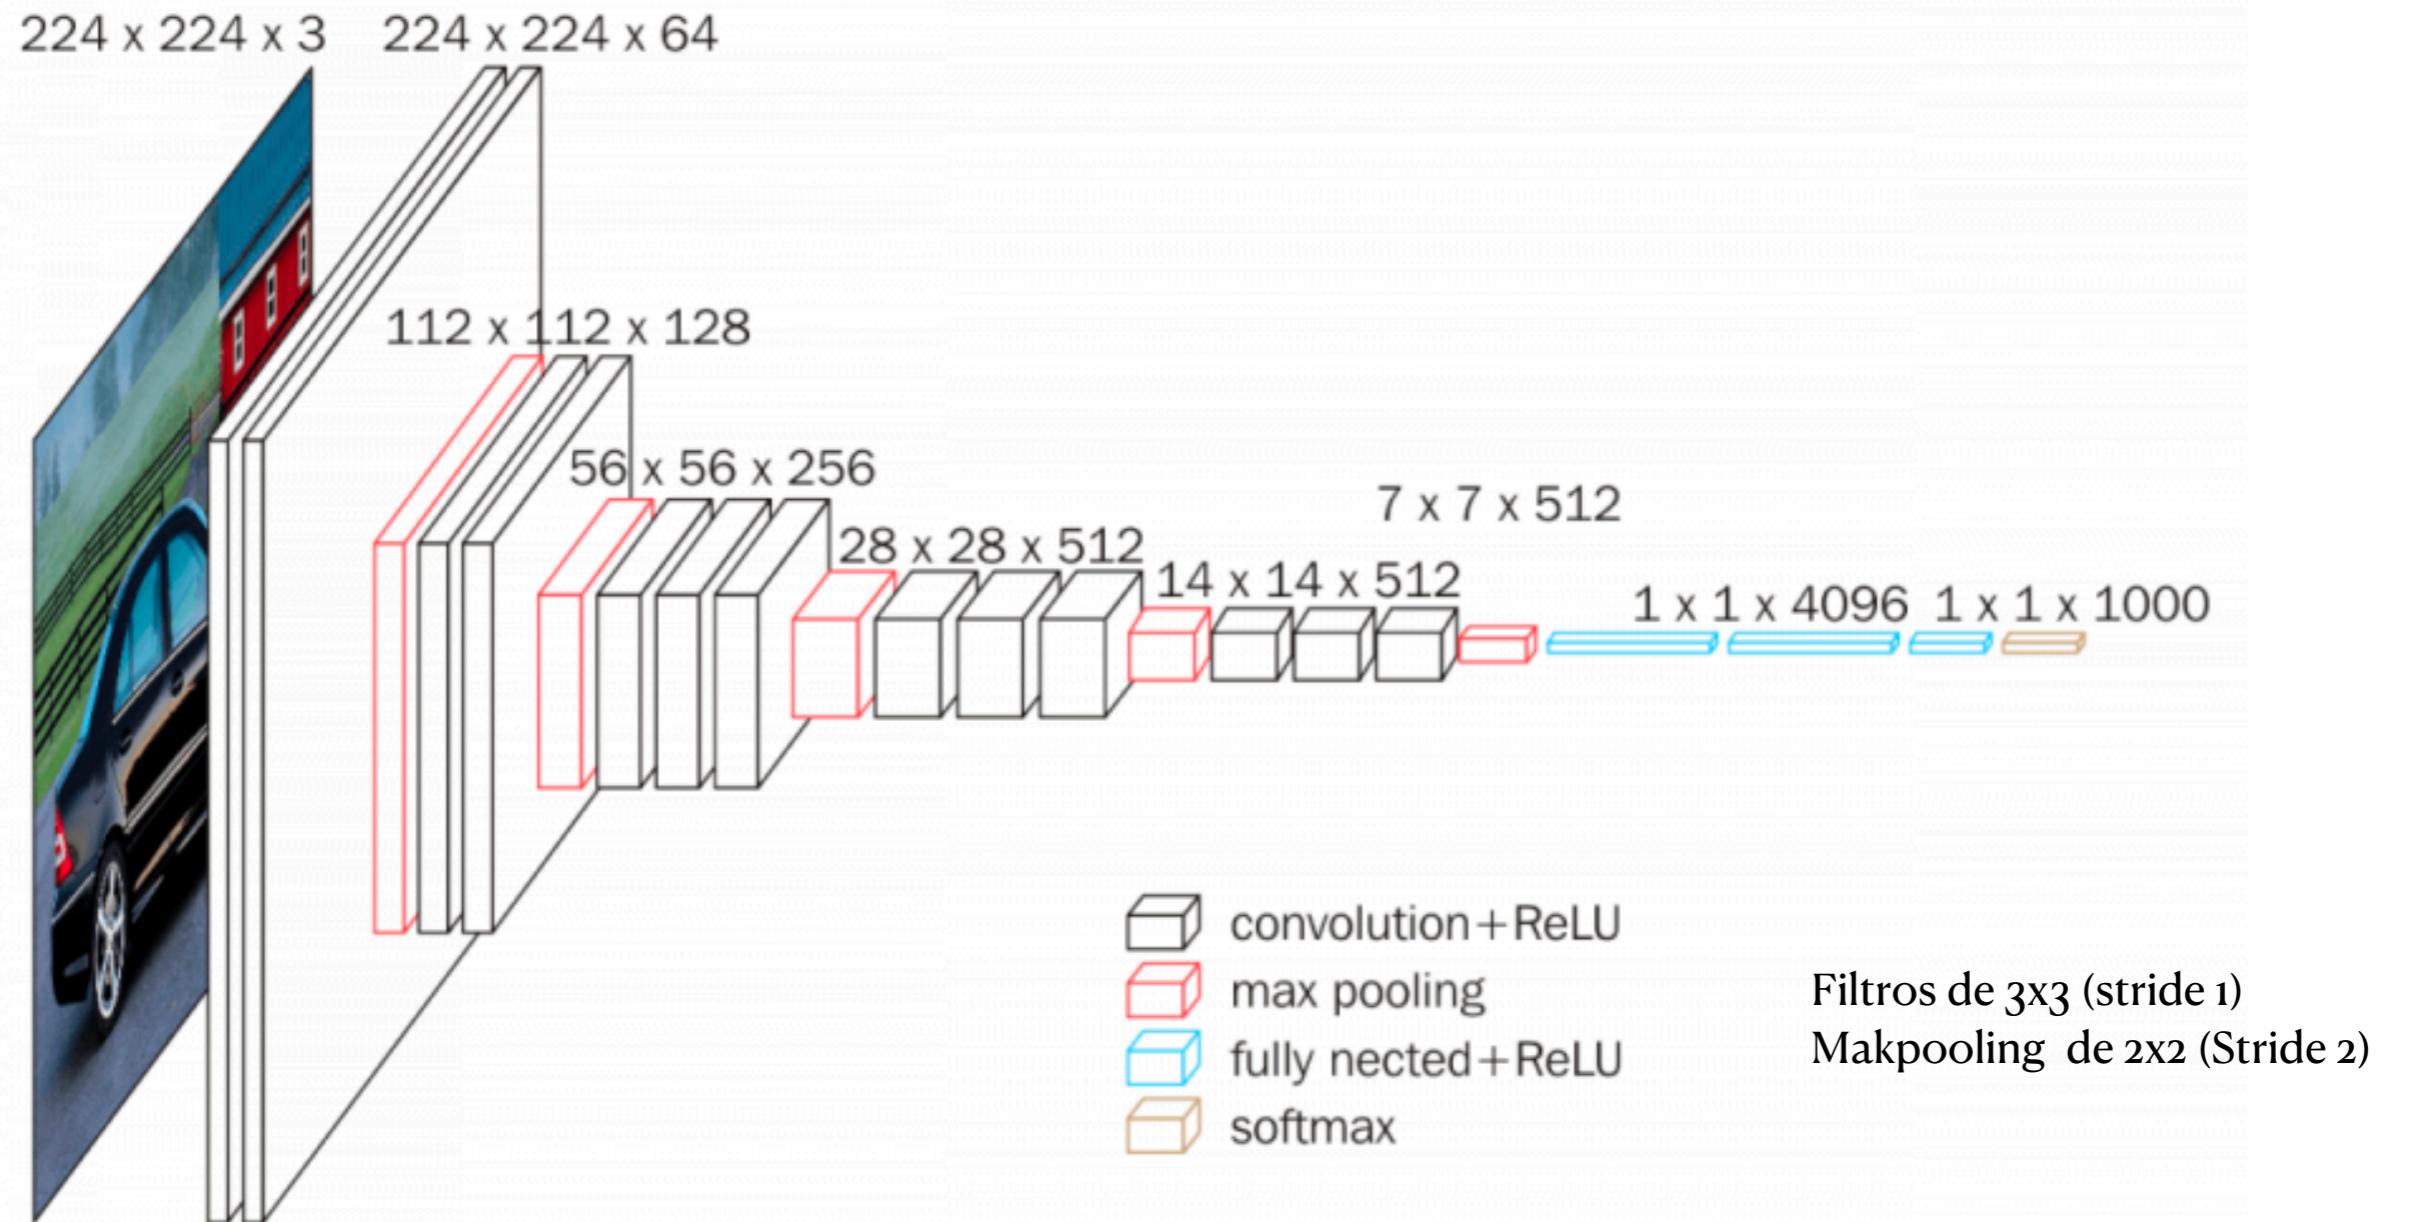


Esta capa ha demostrado grandes resultados en la mejora de la generalización de los modelos y se basa en normalizar la salida del filtro convolucional empleando la media y desviación estándar de ésta.

EJEMPLO

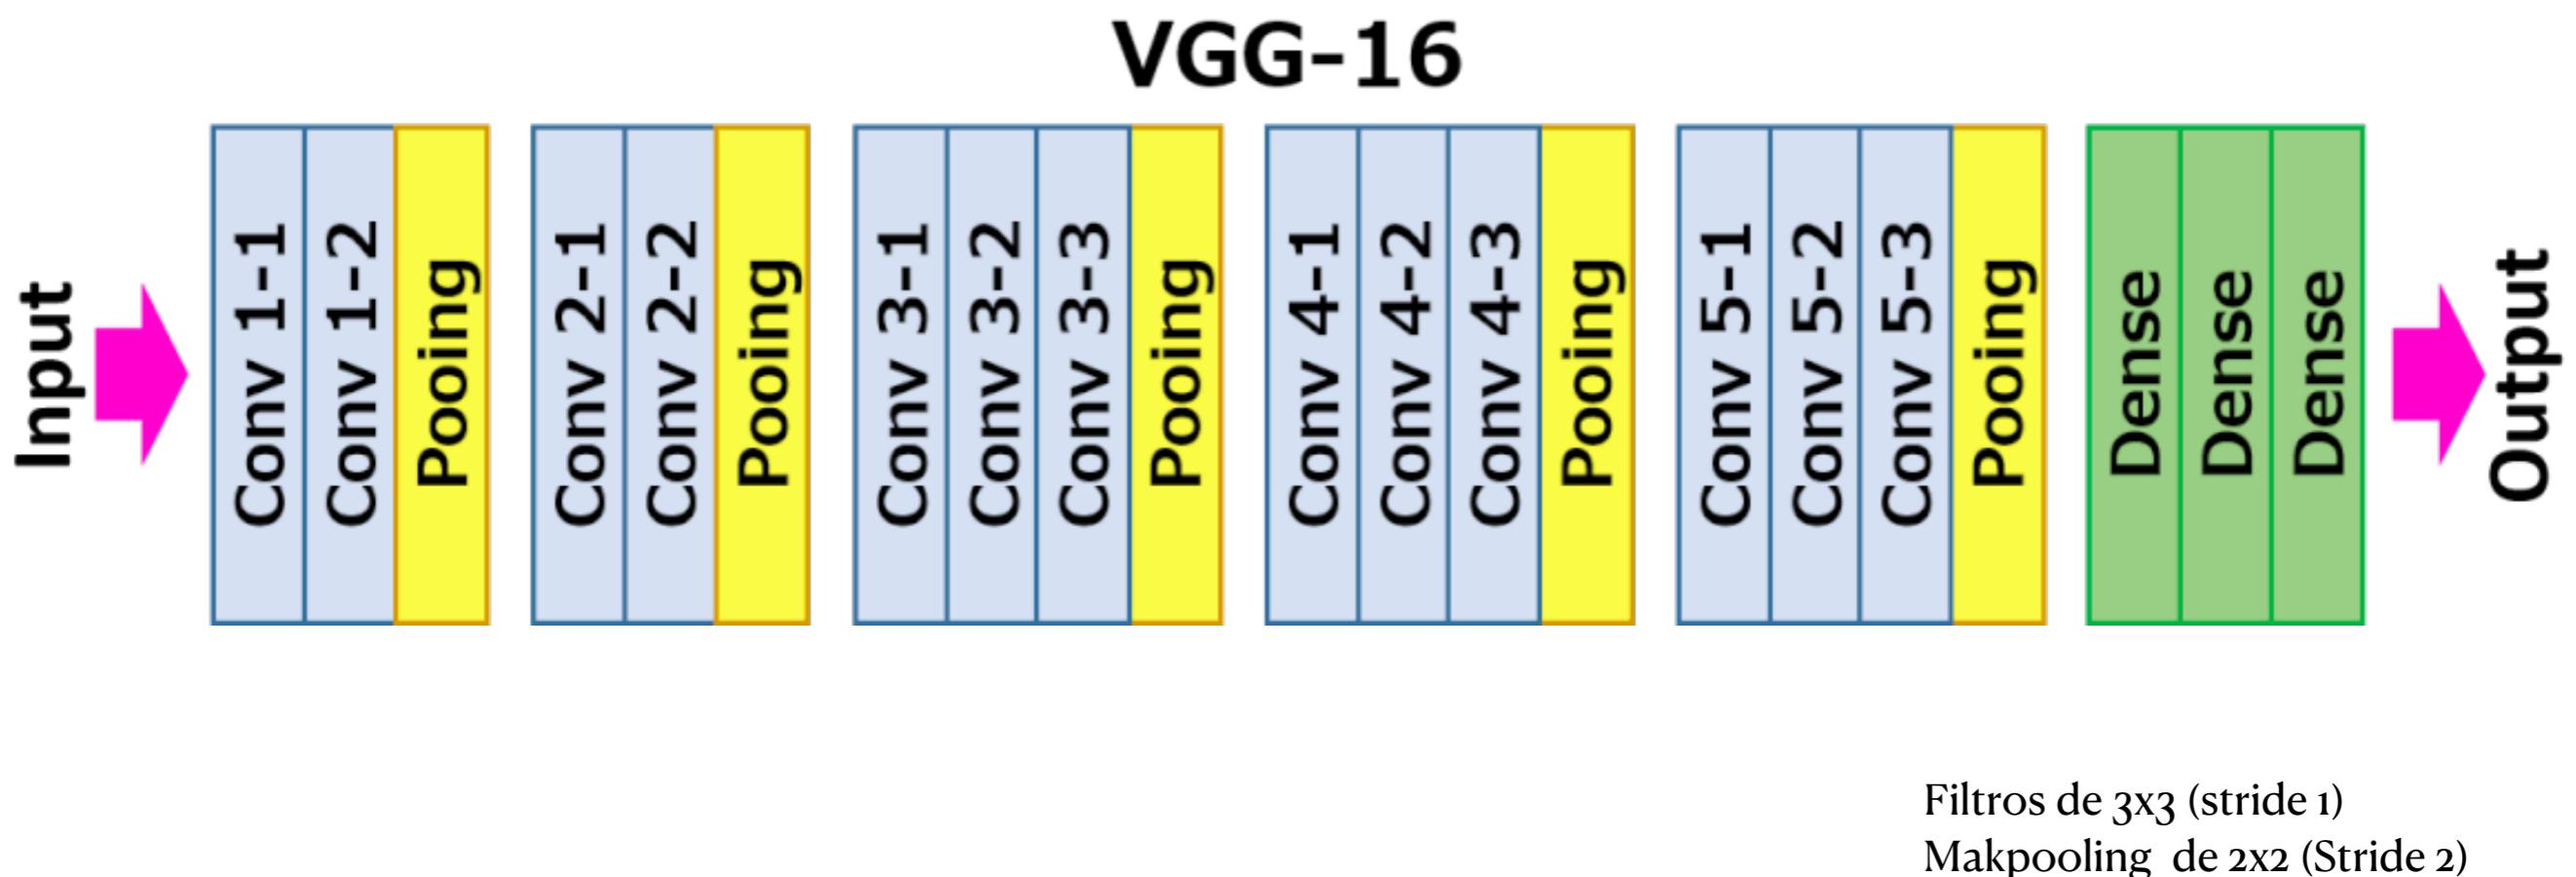
```
model = Sequential([
    Conv2D(32, (3,3), input_shape=(28, 28, 3) activation='relu'),
    BatchNormalization(),
    Conv2D(32, (3,3), activation='relu'),
    BatchNormalization(),
    MaxPooling2D(),
    Dense(2, activation='softmax')
])
```

VGG16 – Convolutional Network for Classification and Detection



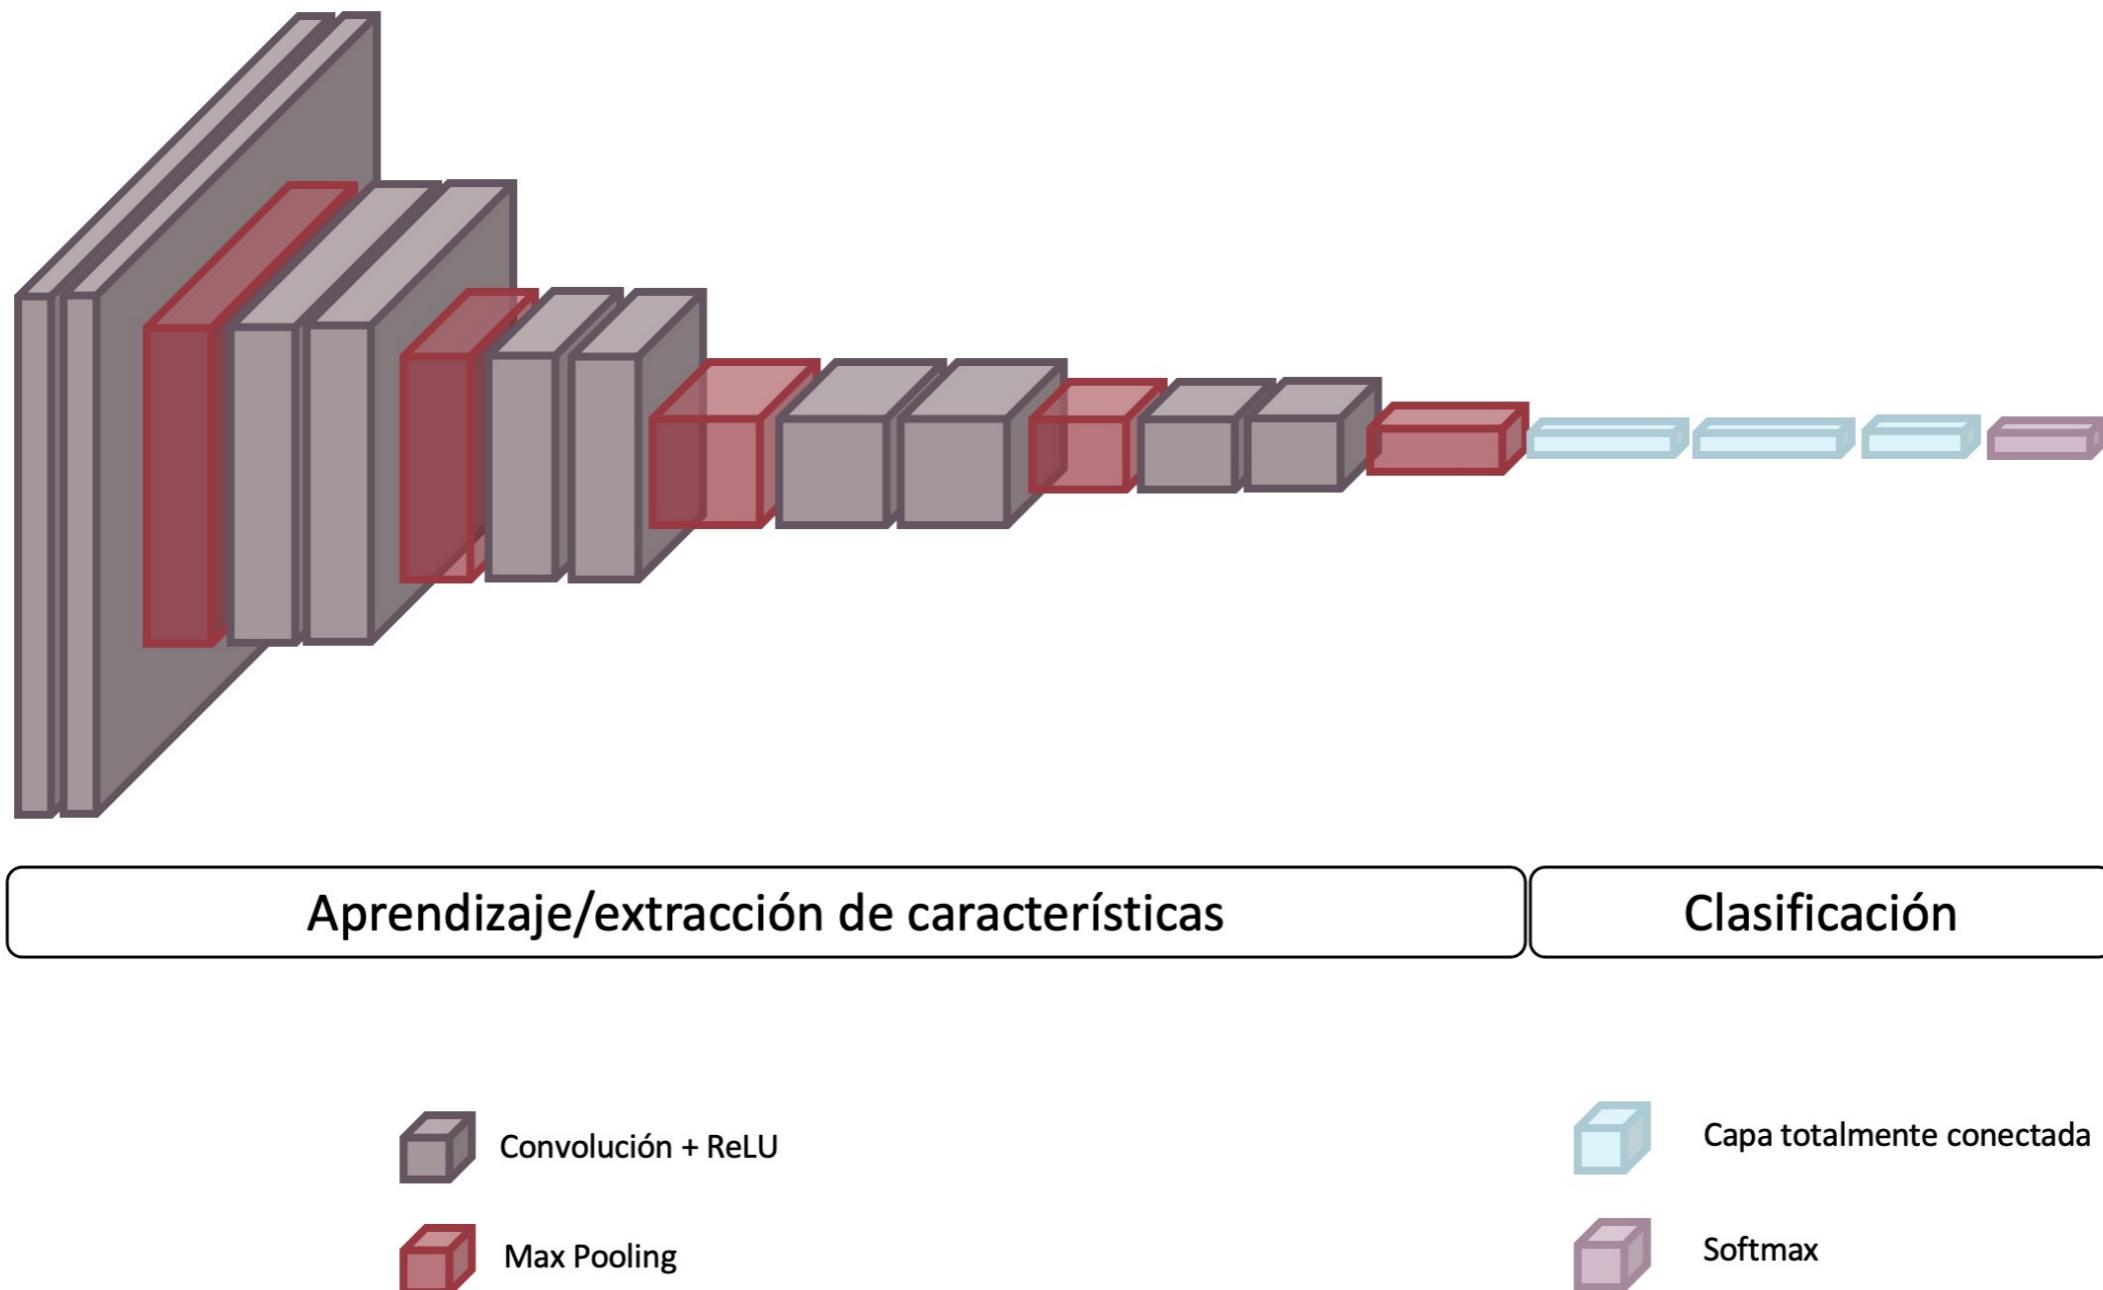
VGG16 se entrenó durante semanas usando NVIDIA Titan Black GPU. Sobre el dataset ImageNet, que es un conjunto de datos de más de 14 millones de imágenes que pertenecen a 1000 clases.

VGG16 – Convolutional Network for Classification and Detection



VGG16 se entrenó durante semanas usando NVIDIA Titan Black GPU. Sobre el dataset ImageNet, que es un conjunto de datos de más de 14 millones de imágenes que pertenecen a 1000 clases.

Ejemplo en Keras (TensorFlow)



Ejemplo en Keras (TensorFlow)



```
from keras.layers import Input, Conv2D, MaxPooling2D, Flatten, Dense
from keras.models import Sequential

# Extraccion caracteristicas
model = Sequential()
model.add(Input(shape=(img_rows, img_cols, img_channels)))
model.add(Conv2D(filters=32, kernel_size=(3,3), padding='same', activation='relu'))
model.add(Conv2D(filters=32, kernel_size=(3,3), padding='same', activation='relu'))
model.add(MaxPooling2D(pool_size = (2,2), strides = (2,2)))

model.add(Conv2D(filters=64, kernel_size=(3,3), padding='same', activation='relu'))
model.add(Conv2D(filters=64, kernel_size=(3,3), padding='same', activation='relu'))
model.add(MaxPooling2D(pool_size = (2,2), strides = (2,2)))

model.add(Conv2D(filters=128, kernel_size=(3,3), padding='same', activation='relu'))
model.add(Conv2D(filters=128, kernel_size=(3,3), padding='same', activation='relu'))
model.add(MaxPooling2D(pool_size = (2,2), strides = (2,2)))

model.add(Conv2D(filters=256, kernel_size=(3,3), padding='same', activation='relu'))
model.add(Conv2D(filters=256, kernel_size=(3,3), padding='same', activation='relu'))
model.add(MaxPooling2D(pool_size = (2,2), strides = (2,2)))

# Clasificación
model.add(Flatten())
model.add(Dense(1024, activation='relu'))
model.add(Dense(512, activation='relu'))
model.add(Dense(2, activation='softmax')) # 2 salidas
```

